

BACHELORARBEIT

Ein systematischer Vergleich von Ansätzen zum "Student
Course Timetable Problem" am Beispiel der
Semesterplanung Studierender der
Wirtschaftsuniversität Wien im Bachelorstudium

verfasst von

Scheer Philipp

angestrebter akademischer Grad

Bachelor of Science (WU), BSc (WU)

Matrikelnummer / student ID number: 12242922

Studium / degree programme: Wirtschafts- und Sozialwissenschaften

Betreut von / Supervisor: Assoz.Prof PD Dr. Stefan Sobernig

Wien, Mai 2026

Inhaltsverzeichnis

1	Einleitung	9
2	Hintergrund	14
2.1	Problemstellung	14
2.2	Zeittafelprobleme	14
2.2.1	University Course Timetabling Problem (UCTTP) . .	15
2.2.2	Student Sectioning Problem (SSP)	15
2.2.3	Single Student Scheduling	16
2.3	Lösungsverfahren	18
2.3.1	Brute-Force als langsames, exaktes Lösungsverfahren .	18
2.3.2	Integer Linear Programming als schnelles, exaktes Lösungsverfahren	19
2.3.3	Heuristische Verfahren als schnelle, nicht exakte Lösungsverfahren	20
2.4	Replikationsarbeit	21
2.4.1	Definition und Arten der Replikation	22
2.4.2	Anforderungen an eine wissenschaftliche Replikation . .	22
3	Zielsetzung und Abgrenzung	23
4	Datenbereitstellung	25
4.1	Datenstruktur	25
4.2	Extraktionsprozess	27
4.3	Deskriptive Analyse	29
5	Analyse	33
5.1	Implementierung des ILP Baseline Ansatzes	33
5.1.1	Variablen, Parameter und Zielfunktion	33
5.1.2	Nebenbedingungen (Constraints)	35
5.1.3	Beispielimplementierung in Python	35
5.1.4	CPU vs. GPU	39
5.2	Implementierung der Hill-Climbing Algorithmen	40
5.2.1	Hill-Climbing v1	40
5.2.2	Hill-Climbing v3	40
5.2.3	Suchstrategie	40
5.2.4	Abbruchkriterien	40
5.2.5	Zur Nicht-Implementierung von Hill-Climbing v2 . . .	41
5.3	Implementierung des Offering-Order Algorithmus	43
5.3.1	Sortierung	43

5.3.2	Suchstrategie	43
5.4	Szenariendefinition	45
5.4.1	Freier Tag	45
5.4.2	Beliebte Zeiten	45
5.4.3	Ähnliche Problemstellungen	46
5.4.4	Vergleichbarkeit	46
5.5	Versuchsaufbau	47
5.5.1	Zielfunktion	47
5.5.2	Durchführung	48
6	Ergebnisse	51
6.1	Szenario 1: Keine Kurse an Montagen	51
6.2	Szenario 2: Keine Kurse an Freitagen	55
6.3	Szenario 3: Jeder Tag der Woche bis 9:45 frei	58
6.4	Szenario 4: Keine Kurse an Donnerstagen und Freitagen . . .	59
6.5	Szenario 5: Erhöhte Priorität (+90) für Nachmittag, negative Priorität (-90) für Abend	60
6.6	Szenario 6: Erhöhte Priorität (+70) für Vormittag, neutrale Priorität (0) für Nachmittag, negative Priorität (-80) für Abend	62
6.7	Szenario 7: Studierende müssen von 12:00 bis 13:00 Zeit für ein Mittagessen haben	64
6.8	Szenario 8: Studierende müssen mehr als einen Kurs pro Tag besuchen	66
6.9	Szenario 9: Studierende dürfen nicht mehr als drei Kurse pro Tag besuchen	69
6.10	Szenario 10: Alle Kurse können frei von Constraints gewählt werden	71
6.11	Szenario 11: 25% – 75% aller Kurse können nicht belegt werden	73
6.12	Szenario 12: 1 – 7 Kurse sind vorgegeben	75
6.13	Szenario 13: Keine Kurse zwischen 6:00 Uhr morgens und 13:00 Uhr	77
6.14	Szenario 14: Keine Kurse am Montag, Dienstag und Mittwoch	79
7	Diskussion	81
7.1	Ergebnisse in der Ursprungsarbeit	81
7.2	Vergleich mit der Ursprungsarbeit	81
7.2.1	Lösungsqualität (Score)	81
7.2.2	Laufzeit und Performance	82
7.3	Eigene Ergebnisse im erweiterten Kontext	82
7.3.1	Der Einfluss moderner Solver (ILP)	82
7.3.2	GPU vs. CPU	83

7.4	Einschränkungen	83
8	Fazit	85
8.1	Anwendungsfälle und Weiterentwicklung	85
8.2	Verwandte Arbeiten	85
8.3	Schlussworte	89
9	Anhang	91
9.1	Szenario 1: Keine Kurse an Montagen	91
9.2	Szenario 2: Keine Kurse an Freitagen	93
9.3	Szenario 3: Jeder Tag der Woche bis 9:45 frei	95
9.4	Szenario 4: Keine Kurse an Donnerstagen und Freitagen . . .	97
9.5	Szenario 5: Erhöhte Priorität (+90) für Nachmittags, negative Priorität (-90) für Abend	99
9.6	Szenario 6: Erhöhte Priorität (+70) für Vormittag, neutrale Priorität (0) für Nachmittags, negative Priorität (-80) für Abend	101
9.7	Szenario 7: Studierende müssen von 12:00 bis 13:00 Zeit für ein Mittagessen haben	103
9.8	Szenario 8: Studierende müssen mehr als einen Kurs pro Tag besuchen	105
9.9	Szenario 9: Studierende dürfen nicht mehr als drei Kurse pro Tag besuchen	107
9.10	Szenario 10: Alle Kurse können frei von Constraints gewählt werden	109
9.11	Szenario 11: 25%- 75% aller Kurse können nicht belegt werden.	111
9.12	Szenario 12: 1 - 7 Kurse sind vorgegeben	113
9.13	Szenario 13: Keine Kurse zwischen 6:00 morgens und 13:00 . .	115
9.14	Szenario 14: Keine Kurse Montags, Dienstags und Mittwochs .	117

Abbildungsverzeichnis

1	Hierarchie von Zeittafelproblemen	17
2	UML Klassendiagramm des Vorlesungsverzeichnis-Modells . .	26
3	Verteilung der <i>Offerings</i> pro <i>Course</i>	29
4	Verteilung der Kurse auf Wochentage	30
5	Verteilung der Kurs-Startzeiten (in Prozent)	31
6	Verteilung der Terminlänge der Buchungsstunden in 15-Minuten- Intervallen	32
7	Mathematische Formulierung des ILP-Modells zur Stunden- planoptimierung	34

Tabellenverzeichnis

1	Auszug des Ergebnisses der Datenbereitstellung	28
2	Übersicht der Forschungsliteratur zu University Timetabling Problemen	89

Listings

1	Modellinitialisierung und Zielfunktion	36
2	Feste Zuordnungen und Kursanzahl	37
3	Gruppen-Beschränkung	37
4	Tägliche Auslastung	38
5	Zeitliche Überschneidungen	39

Zusammenfassung

Die Erstellung eines konfliktfreien und präferenzgerechten Semesterplans stellt Studierende vor ein kombinatorisches Optimierungsproblem, für das an der Wirtschaftsuniversität Wien (WU) bislang keine automatisierten Lösungen existieren. Diese Bachelorarbeit knüpft an die algorithmischen Grundlagen von Feldman und Golumbic (1990) an, die mit *Hill-Climbing* und *Offering-Order* zwei heuristische Verfahren für das *Single Student Scheduling Problem (SSP)* vorschlugen, und unterzieht diese einer konzeptionellen Replikation mit Erweiterung. Da weder der originale Datensatz noch eine Referenzimplementierung verfügbar sind, wurden die Algorithmen auf Basis des Pseudocodes neu implementiert und anhand eines realen Datensatzes des Hauptstudiums Wirtschaftsinformatik der WU (Sommersemester 2025, 381 Kurse, 28 Planpunkte) evaluiert. Da *Brute-Force* für diesen Datensatz rechnerisch nicht praktikabel ist, wurde als zeitgemäße *Baseline* ein *Integer Linear Programming*-Ansatz (ILP via CBC/Gurobi) eingeführt, der dieselbe Rolle übernimmt wie *Brute-Force* in der Ursprungsarbeit. Die Algorithmen wurden in 14 Szenarien — abgeleitet aus empirischen Studien zu studentischen Präferenzen sowie klassischen *Constraints* aus der *Timetabling*-Literatur — systematisch hinsichtlich Lösungsqualität, Laufzeit und Speicherbedarf verglichen. Die Ergebnisse bestätigen, dass *Offering-Order* in der Laufzeit konsistent schneller ist als beide *Hill-Climbing*-Varianten, während *Hill-Climbing* in der Lösungsqualität in den meisten Szenarien überlegen ist. Das überraschendste Ergebnis ist, dass moderne ILP-*Solver* als exakte Verfahren die heuristischen Verfahren in der Laufzeit in fast allen Szenarien übertreffen — womit ein Trade-off zwischen Lösungsqualität und Geschwindigkeit für Probleminstanzen dieser Größenordnung nicht mehr gilt.

Keywords: Student Scheduling Problem, Single Student Scheduling, Hill-Climbing, Offering-Order, Integer Linear Programming, Replikationsstudie, Stundenplanoptimierung, Wirtschaftsuniversität Wien

1 Einleitung

Kaum eine Entscheidung im Alltag von Studierenden erscheint so simpel und erweist sich gleichzeitig als so komplex wie die Erstellung des eigenen Stundenplans. Was auf den ersten Blick nach einer organisatorischen Routineaufgabe aussieht, entpuppt sich bei näherer Betrachtung als vielschichtiges Optimierungsproblem: Überschneidungen zwischen Lehrveranstaltungen, begrenzte Kursplätze und individuelle Präferenzen wie Arbeitszeiten und Lerngewohnheiten machen die Planung zu einer Herausforderung.

In einer Zeit, in der viele Entscheidungsprozesse bereits durch Algorithmen unterstützt werden, stellt sich die Frage, ob auch die Stundenplanerstellung automatisiert und optimiert werden kann. Hier setzt die folgende Arbeit an: Sie untersucht, wie sich das *Student Scheduling Problem (SSP)* mithilfe von verschiedenen Optimierungsverfahren modellieren und lösen lässt.

Studierende sehen sich im Studium mit einem umfangreichen Kursangebot konfrontiert und müssen ihre Stundenpläne meist ohne Entscheidungsunterstützung zusammenstellen. Dieser manuelle Prozess ist jedoch mehr als eine rein administrative Aufgabe; er ist eine Optimierungsentscheidung, bei der persönliche, curriculare und universitäre Rahmenbedingungen gegeneinander abgewogen werden müssen.

Obwohl systematische Erhebungen für österreichische Hochschulen bislang fehlen, deuten internationale Befragungen — etwa an britischen und malaysischen Universitäten sowie der Hochschule Trier — darauf hin, dass Studierende häufig Schwierigkeiten bei der Vereinbarkeit ihres Stundenplans mit anderen Verpflichtungen haben [1–3]. Zu den zentralen Ursachen zählt insbesondere die Vereinbarkeit mit einem Nebenjob; so bevorzugen 81% der Befragten mindestens einen vollständig freien Wochentag [3]. Zudem geben 74% der Studierenden an, dass eine gleichmäßige Verteilung von Lehrveranstaltungen und Prüfungen für sie das wichtigste Kriterium bei der Stundenplanerstellung darstellt [4]. Weiterhin möchten 82% vermeiden, mehr als eine Prüfung pro Tag zu absolvieren [4]. Bezüglich der zeitlichen Präferenzen werden Mittagsstunden am häufigsten gewählt, gefolgt von frühen und späten Zeitslots. Rund 31% der Studierenden bevorzugen es, an bestimmten Tagen keine Prüfungen zu haben; besonders unpopulär sind Samstag, Sonntag, Freitag und Montag [4].

Obwohl sich diese Präferenzen grundsätzlich leicht modellieren lassen, stehen derzeit keine Programme zur Verfügung, die eine automatisierte Erstellung entsprechender Stundenpläne an der WU ermöglichen. Lediglich der Studienplaner der Österreichischen Hochschüler*innenschaft der WU [5] erlaubt die manuelle Kombination von Lehrveranstaltungen und Prüfungen im Hinblick auf Überschneidungsfreiheit, bietet jedoch keine Möglichkeit zur

Optimierung nach individuellen Präferenzen.

Bestehende Lösungen zur Stundenplanung im universitären Umfeld lassen sich grob in zwei Kategorien unterteilen: institutionelle Planungssysteme und studentenzentrierte Entscheidungsunterstützung.

Auf institutioneller Ebene existieren ausgereifte Softwarelösungen wie UniTime [6, 7], ein quelloffenes System der Apereo Foundation, das Universitäten bei der Erstellung konfliktfreier Master-Stundenpläne unterstützt und dabei das *Student Sectioning Problem* berücksichtigt. Ähnliche kommerzielle Lösungen wie Infosilem [8] oder Coursedog [9] adressieren ebenfalls die Ressourcenplanung aus Sicht der Institution - also die in Kapitel 2.2.1 und 2.2.2 beschriebenen Problemebenen. Diese Systeme sind jedoch auf die Bedürfnisse von Administrierenden ausgelegt und lösen das Problem der Stundenplanerstellung aus der Perspektive der gesamten Universität, nicht des einzelnen Studierenden.

Auf studentenzentrierter Ebene gibt es eine Reihe von Kalender- und Planungsapps wie MyStudyLife [10] oder den uAchieve Schedule Builder [11], die es Studierenden erlauben, bereits fixierte Lehrveranstaltungen zu verwalten und in einem persönlichen Kalender darzustellen. Diese Tools setzen jedoch voraus, dass der Studierende seine Kurswahl bereits getroffen hat - eine Optimierung nach individuellen Präferenzen findet nicht statt.

Im österreichischen Kontext bietet der Studienplaner der Österreichischen Hochschüler*innenschaft der WU [5] die Möglichkeit, Lehrveranstaltungen manuell auf Überschneidungsfreiheit zu prüfen. Auch dieses Tool optimiert jedoch nicht nach individuellen Präferenzen wie freien Tagen, bevorzugten Zeitslots oder der Vereinbarkeit mit einem Nebenjob.

Die beschriebene Lücke — ein automatisiertes, präferenzbasiertes System zur Erstellung individueller Stundenpläne auf Basis des tatsächlichen WU-Kursangebots — ist der Ausgangspunkt der vorliegenden Arbeit.

Feldman und Golumbic [12] entwickelten bereits 1990 algorithmische Ansätze für genau dieses Problem. Ihre Arbeit wurde seither jedoch nie mit realen, aktuellen Universitätsdaten validiert — und ein systematischer Vergleich ihrer heuristischen Verfahren mit modernen exakten Lösungsmethoden wie *Integer Linear Programming* (ILP) existiert unseres Wissens bis heute nicht. Während Feldman und Golumbic ihre Algorithmen ausschließlich gegen *Brute-Force* verglichen und auf synthetischen Kleinstinstanzen testeten, bleibt offen, ob ihre Heuristiken unter realen Bedingungen — mit einem echten, größeren Datensatz und im Vergleich zu modernen ILP-*Solvern* — noch konkurrenzfähig sind. Genau hier setzt die vorliegende Arbeit an: Sie knüpft an die algorithmischen Grundlagen von Feldman und Golumbic [12] an, überprüft deren Anwendbarkeit unter heutigen Bedingungen anhand eines realen WU-Datensatzes und stellt erstmals einen systematischen Vergleich zwischen

den historischen Heuristiken und einem modernen ILP-Ansatz an. Dieser Ansatz wird in der Wissenschaft als Replikationsstudie bezeichnet — konkret als konzeptionelle Replikation mit Erweiterung —, da geprüft wird, ob Ergebnisse einer früheren Arbeit unter veränderten Rahmenbedingungen standhalten. Was das konkret bedeutet und wie diese Arbeit dabei vorgeht, wird in Kapitel 2.4 erläutert.

Eine exakte Replikation — also die Reproduktion der ursprünglichen Ergebnisse mit denselben Daten und derselben Implementierung — wäre in diesem Fall grundsätzlich nicht möglich: Weder der originale Datensatz von Feldman und Golumbic noch eine Referenzimplementierung der Algorithmen sind verfügbar. Zudem lässt der in der Originalarbeit beschriebene Pseudocode an mehreren Stellen Interpretationsspielraum offen, was eine Nachbildung erschwert. Ziel dieser Arbeit ist es daher nicht, die exakten Ergebnisse von 1990 zu reproduzieren, sondern die Validität der vorgeschlagenen Lösungsansätze (*Hill-Climbing* und *Offering-Order*) in einem neuen Kontext zu überprüfen. Dies entspricht der von Burman et al. [13] beschriebenen validierenden Replikation, bei der geprüft wird, ob Ergebnisse robust gegenüber Veränderungen in Datensätzen und Zeiträumen sind.

Um die wissenschaftlichen Anforderungen an diese Replikation zu erfüllen, werden in dieser Arbeit folgende Maßnahmen getroffen:

- **Methodische Treue:** Die Algorithmen werden basierend auf der Beschreibung in der Originalarbeit von Feldman und Golumbic [12] exakt nachprogrammiert (*re-implemented*), um die methodische Vergleichbarkeit zu gewährleisten.
- **Neuer Datensatz:** Die Evaluation erfolgt anhand eines aktuellen, realen Datensatzes der Wirtschaftsuniversität Wien (Sommersemester 2025).
- **Erweiterte *Baseline*:** Da der ursprüngliche Vergleichsmaßstab (*Brute-Force*) für die Komplexität des neuen Datensatzes nicht praktikabel ist, wird eine neue *Baseline* mittels *Integer Linear Programming* (ILP) eingeführt. Dies stellt eine methodische Modernisierung dar, wahrt aber das Ziel, die heuristischen Verfahren gegen eine optimale Lösung zu benchmarken.
- **Transparenz (*Computational Reproducibility*):** Im Sinne der „Ten Simple Rules“ von Sandve et al. [14] werden alle Schritte der Datenextraktion und Analyse dokumentiert. Der Quellcode der Implementierungen ist, wie in der Arbeit referenziert, öffentlich einsehbar, um vollständige Nachvollziehbarkeit zu garantieren [15].

Die vorliegende Bachelorarbeit leistet folgende wesentliche Beiträge:

- Die Algorithmen von Feldman und Golumbic [12] — *Hill-Climbing v1*, *Hill-Climbing v3* und *Offering-Order* — wurden nachprogrammiert und mit einem aktuellen Datensatz der Wirtschaftsuniversität Wien (Hauptstudium Wirtschaftsinformatik [16, S. 13f], Sommersemester 2025) evaluiert. Die Ergebnisse der Ursprungsarbeit konnten bestätigt werden.
- **Überlegenheit der Hill-Climbing-Varianten:** In den meisten der 14 getesteten Szenarien erzielten *Hill-Climbing v1* und *v3* eine höhere Lösungsqualität (*Mark*) als der *Offering-Order*-Algorithmus. Insbesondere bei Szenarien mit vorgegebenen Kursen (Szenario 12) kann man die Schwäche der statischen Sortierung sehen: Der Algorithmus verfängt sich in lokalen Optima und erfüllt in manchen Fällen die Mindestanzahl an zu wählenden Lehrveranstaltungen nicht. *Offering-Order* war jedoch in allen Szenarien die schnellste Heuristik.
- **Effizienz moderner ILP-Solver:** Ein zentrales und unerwartetes Ergebnis dieser Arbeit ist, dass ein moderner *Integer Linear Programming-Solver* (CBC/Gurobi via Python-MIP) die heuristischen Algorithmen in der Laufzeit in fast allen Szenarien übertrifft. Lediglich in Szenario 8 („Mehr als ein Kurs pro Tag“) war der ILP-Ansatz langsamer als die Heuristiken.
- **GPU vs. CPU:** Der Vergleich einer GPU-optimierten ILP-Implementierung (NVIDIA RTX A5000, CUDA 12.4) mit der CPU-Variante zeigt, dass die GPU-Implementierung bei kleinen und mittleren Probleminstanzen langsamer ist als die CPU, jedoch bei steigender Komplexität aufholt.

Um die Nachvollziehbarkeit dieser Replikationsstudie zu gewährleisten, sind alle im Rahmen dieser Arbeit entstandenen Materialien öffentlich zugänglich. Das zentrale Repository [15] umfasst die Implementierungen aller Algorithmen, den extrahierten Vorlesungsdatsatz, die Konfigurationsdateien aller 14 Testszenarien sowie die vollständigen Rohdaten der Benchmarks inklusive Auswertungsskripten.

Die Umsetzung dieser Arbeit war mit einer Reihe von Herausforderungen verbunden, die im Folgenden kurz skizziert werden.

- **Unvollständiger Pseudocode:** Die zentrale Schwierigkeit war die exakte Nachprogrammierung der Algorithmen von Feldman und Golumbic [12]. Der in der Originalarbeit beschriebene Pseudocode lässt an

mehreren Stellen Interpretationsspielraum offen, was für eine Replikationsstudie besondere Sorgfalt erfordert. Da keine Referenzimplementierungen oder aktuellen Codebeispiele verfügbar sind, mussten Unklarheiten durch eigene Interpretation und iteratives Testen aufgelöst werden. Dies betrifft insbesondere die Zielfunktion (*Mark*), deren exakte Berechnung ebenfalls nicht vollständig spezifiziert ist und daher auf Basis der Beschreibung im Paper rekonstruiert werden musste.

- **Rekursive Implementierung des Offering-Order-Algorithmus:** Der *Offering-Order*-Algorithmus basiert auf einer rekursiven *Backtracking*-Strategie. Die korrekte Implementierung dieser Rekursion erforderte einige Iterationen.
- **Testumgebung mit *benchexec*:** Die Einrichtung der Testumgebung mittels *benchexec* [17] gestaltete sich aufwändiger als erwartet. Das Tool ist extrem umfangreich und eine Implementierung für die „einfache“ Messung von Laufzeit und Speichernutzung erforderte einige Einarbeitungszeit.
- **Datenbeschaffung:** Der automatisierte *Scraping*-Prozess der Vorlesungsdaten aus dem Vorlesungsverzeichnis der WU (vgl. Kapitel 4.2) stellte eine Herausforderung dar, da keine offizielle Schnittstelle zur Verfügung steht und die Auszeichnungsstruktur der Webseite zuerst entsprechend analysiert werden musste.

Die Arbeit gliedert sich in acht Kapitel. Kapitel 2 legt die theoretischen Grundlagen fest, verortet die Arbeit innerhalb der Hierarchie der Zeittafelprobleme — vom *University Course Timetabling Problem* über das *Student Sectioning Problem* bis hin zum *Single Student Scheduling* — und erläutert die wissenschaftlichen Anforderungen an eine Replikationsstudie. Kapitel 3 präzisiert die Zielsetzung und grenzt den Forschungsumfang ab. Kapitel 4 beschreibt die Datengrundlage der Arbeit und gibt einen Überblick über die Struktur des Vorlesungsdatensatzes. Kapitel 5 bildet den methodischen Kern mit der Beschreibung der implementierten Algorithmen, der 14 Testszenarien und des Versuchsaufbaus. Die Ergebnisse werden in Kapitel 6 szenarioweise präsentiert, in Kapitel 7 diskutiert und in Bezug zur Ursprungsarbeit gesetzt. Kapitel 8 schließt die Arbeit mit einem Fazit ab.

2 Hintergrund

2.1 Problemstellung

Die Erstellung eines optimalen Semesterplans ist eine zentrale Herausforderung für Studierende. Das Angebot an Lehrveranstaltungen lässt sich nicht frei kombinieren, da auf zeitliche Konflikte, Erfüllung einer Mindestanzahl an ECTS pro Semester, Arbeitstätigkeit, etc. geachtet werden muss. Die Herausforderung besteht darin, aus diesem Pool an Lehrveranstaltungen eine zulässige und optimale Kombination zu wählen. Als zulässig gilt eine Zeittafel, wenn keine zeitlichen Konflikte auftreten (keine *Hard Constraints* wurden verletzt). Optimal ist eine Zeittafel, wenn eine gegebene Zielfunktion maximal ist. Die Zielfunktion beinhaltet alle Präferenzen des Studierenden, die seine Lebensrealität widerspiegeln sollen (*Soft Constraints*). Dazu zählen etwa die Berücksichtigung von Arbeitstätigkeiten, die durch Blockieren oder Priorisieren von gewissen Stunden in der Woche ausgedrückt werden, sowie die Favorisierung von Kursen, die durch eine Priorität ausgedrückt wird. Diese Problemstellung wird in der Literatur als Zeittafelproblem oder *Student Scheduling Problem* bezeichnet.

2.2 Zeittafelprobleme

Zeittafelprobleme werden als Unterkategorie kombinatorischer Optimierungsprobleme gesehen, bei denen Aktivitäten (z.B. Lehrveranstaltungen, Prüfungen oder Schichten) unter Einhaltung von *Hard Constraints* und *Soft Constraints* auf Ressourcen wie Zeitfenster und Räume verteilt werden. *Educational Timetabling* ist wiederum eine Unterkategorie der Zeittafelprobleme, die sich speziell mit Optimierungsproblemen im Bildungskontext beschäftigt [18].

Innerhalb der *Educational-Timetabling*-Forschung hat sich ein Standard etabliert, der *High-School-Timetabling*, *University Course Timetabling* und *Examination Timetabling* als grundlegende Problemfamilien unterscheidet. Diese Probleme sind in der Regel NP-schwer, was bedeutet, dass mit wachsender Problemgröße und zunehmender Zahl an *Constraints* keine effizienten exakten Algorithmen bekannt sind und daher heuristische Ansätze angewandt werden. Carter und Laporte [19] zeigen anhand des *Examination Timetabling*, dass realistische Probleminstanzen typischerweise nur mit Heuristiken, die an das Problem angepasst sind, z.B. *Greedy*-Konstruktionen, *Tabu Search* oder *Simulated Annealing*, praktikabel lösbar sind, und prägen damit die algorithmische Behandlung von Zeittafelproblemen im universitären Umfeld [19].

Die im weiteren Verlauf dieser Arbeit betrachtete Hierarchie vom *University Course Timetabling* über das *Student Sectioning* bis hin zum *Single Student Scheduling* lässt sich als zunehmende Individualisierung innerhalb der Problemfamilie der *Educational-Timetabling*-Probleme interpretieren: Während beim *University Course Timetabling* institutionelle Zielfunktionen wie Auslastung und Konfliktfreiheit auf Ebene der gesamten Organisation im Vordergrund stehen, rücken beim *Student Sectioning* kohorten- und gruppenspezifische *Constraints* in den Fokus. *Single Student Scheduling* ist schließlich die feinste Granularität, in der die Zielfunktion auf die Nutzenmaximierung eines einzelnen Studierenden ausgelegt ist, die sich durch persönliche Präferenzen (z.B. Mindest-ECTS pro Semester, Freie Tage, etc.) ergibt und damit einen studentenzentrierten Spezialfall der allgemeinen Zeittafel- und *Scheduling*-Probleme bildet [7, 20].

2.2.1 University Course Timetabling Problem (UCTTP)

Auf der obersten Ebene steht das *University Course Timetabling Problem* (UCTTP). Dieses Problem befasst sich mit der Erstellung des „Master-Stundenplans“. Die Kernaufgabe besteht darin, eine Menge von Lehrveranstaltungen (*Events*) einer Menge von Zeitfenstern und Räumen zuzuordnen [21]. Dabei müssen Ressourcenbeschränkungen (z. B. Raumgrößen) und *Hard Constraints*, wie die Verfügbarkeit von Lehrenden, berücksichtigt werden.

Carter und Laporte beschreiben dieses Problem als NP-hart [19]. Das bedeutet, dass mit steigender Anzahl an Veranstaltungen und Restriktionen der Rechenaufwand für eine exakte Lösung exponentiell wächst. Das Ziel des UCTTP ist hauptsächlich die Machbarkeit und Effizienz aus Sicht der Institution: Es muss sichergestellt werden, dass alle Kurse stattfinden können, ohne dass Lehrende oder Räume doppelt belegt werden. Individuelle Studierendenpräferenzen spielen auf dieser Ebene oft nur eine untergeordnete Rolle oder werden aggregiert betrachtet.

2.2.2 Student Sectioning Problem (SSP)

Sobald der Master-Stundenplan fixiert ist (die Veranstaltungen haben feste Zeiten und Räume), folgt die nächste Ebene: das *Student Sectioning Problem* (SSP). Hier verlagert sich der Fokus von der Ressourcenzuordnung (Wann findet der Kurs statt?) zur Belegung (Wer besucht welchen Kurs?).

Das SSP befasst sich mit der Verteilung der Studierenden auf Übungsgruppen oder Parallelveranstaltungen (Sections) eines Kurses [7]. Ein klassisches Beispiel ist ein Modul, das aus einer zentralen Vorlesung und zehn verschiedenen Labor-Terminen besteht. Das Ziel ist es, alle Studierenden so

auf die Labore zu verteilen, dass Überschneidungen vermieden und Kapazitätsgrenzen eingehalten werden. Müller et al. unterscheiden hierbei zwei Ansätze [7]:

1. **Batch Sectioning:** Alle Studierendenwünsche werden gesammelt und global optimiert. Das maximiert die Fairness und die Gesamtauslastung, findet aber meist vor Semesterbeginn statt.
2. **Online Sectioning:** Die Zuteilung erfolgt sequenziell in Echtzeit (z. B. während der Anmeldephase via LPIS im Kontext der WU). Dies entspricht einem *Greedy*-Ansatz, bei dem für späte Anmeldungen oft nur suboptimale Restplätze vergeben werden können.

2.2.3 Single Student Scheduling

Die granularste Ebene der Hierarchie — und der Fokus dieser Bachelorarbeit — ist das *Single Student Scheduling*. Während das SSP versucht, eine Menge von Studierenden global auf Kurse aufzuteilen, betrachtet das *Single Student Scheduling* das Problem ausschließlich aus der Perspektive eines einzelnen Studierenden.

Die Fragestellung lautet hier nicht: „Wie fülle ich die Kursräume optimal?“, sondern: „Welche Kombination aus den verfügbaren Kursangeboten maximiert meinen persönlichen Nutzen?“ [22].

Obwohl der Suchraum für einen einzelnen Studierenden deutlich kleiner ist als für die gesamte Universität, bleibt die Komplexität hoch. Da ein Studierender oft aus hunderten möglichen Kombinationen von Vorlesungen und Übungen wählen kann, die unterschiedliche zeitliche Attribute und Abhängigkeiten aufweisen, handelt es sich auch hier um ein kombinatorisches Optimierungsproblem. Die Herausforderung besteht darin, harte Restriktionen (keine zeitlichen Überschneidungen) zu erfüllen und gleichzeitig weiche Restriktionen (z. B. „keine Kurse am Freitag“, „kompakter Stundenplan“) zu optimieren.




Abbildung 1: Hierarchie von Zeittafelproblemen
(adaptiert aus [23])

2.3 Lösungsverfahren

2.3.1 Brute-Force als langsames, exaktes Lösungsverfahren

Der einfachste Ansatz zur exakten Lösung des *Student Scheduling Problems* ist es, alle möglichen Stundenplankombinationen mit der Zielfunktion zu bewerten. Das globale Optimum ist damit garantiert auffindbar, da keine Kombination ausgelassen wird.

Der Nachteil dieses Ansatzes liegt in der Komplexität: Die Anzahl der zu prüfenden Kombinationen wächst exponentiell mit der Problemgröße. Feldman und Golumbic nutzten *Brute-Force* in ihrer Arbeit von 1990 als *Baseline*, was für die dort betrachteten kleinen Probleminstanzen („30 courses“, was als 30 *Offerings* interpretiert wurde [12]) praktikabel war. Die Begriffe *Course* und *Offering* bezeichnen zwei zentrale Entitäten des Modells, die in Kapitel 4.1 näher definiert werden; an der WU entsprechen diese einem Planpunkt bzw. einem Kurs. Für den WU-Datensatz dieser Arbeit wäre ein *Brute-Force*-Ansatz rechnerisch nicht mehr durchführbar. Bereits eine Teilmenge der zehn *Courses* mit den meisten *Offerings* – konkret mit 44, 42, 40, 38, 33, 33, 31, 26, 22 und 14 *Offerings* (vgl. Kapitel 4.3) – ergibt $\approx 7,59 \times 10^{14}$ zu prüfende Kombinationen. Bei einer angenommenen Rechenleistung von 10^9 Operationen pro Sekunde entspräche allein diese Teilmenge einer Laufzeit von knapp 9 Tagen – weit zu lang, um als interaktive Planungsassistentz eingesetzt werden zu können, wo ein Student eine Antwort in Sekunden erwartet, nicht in Tagen [24].

Die Frage, wie ein exaktes Verfahren dennoch für größere Probleminstanzen eingesetzt werden kann, beantwortet ein Ansatz, der seit den 1990er Jahren erheblich an praktischer Bedeutung gewonnen hat: *Integer Linear Programming* [25, 26].

2.3.2 Integer Linear Programming als schnelles, exaktes Lösungsverfahren

Integer Linear Programming (ILP) ist ein mathematisches Optimierungsverfahren, das auf linearer Programmierung basiert. Zusätzlich müssen einige oder alle Entscheidungsvariablen ganzzahlig sein. Für kombinatorische Optimierungsprobleme wie das *Student Scheduling Problem* ist diese Eigenschaft wichtig, da Entscheidungen wie „Kurs wird belegt“ oder „Kurs wird nicht belegt“ von Natur aus binär sind.

Während ILP als Verfahren bereits in den 1950er Jahren entwickelt wurde, war seine praktische Anwendbarkeit auf reale Probleminstanzen lange Zeit durch die verfügbare Rechenleistung stark eingeschränkt. Feldman und Golumbic griffen in ihrer Arbeit von 1990 daher auf *Brute-Force* als *Baseline* zurück. Für kleine Probleminstanzen, wie sie 1990 untersucht wurden, war dies praktikabel. Für die Größenordnung des WU-Datensatzes mit 381 *Offerings* und 28 *Courses* ist ein *Brute-Force*-Ansatz jedoch rechnerisch nicht mehr durchführbar [25, 26].

Seit den 1990er Jahren haben sich ILP-*Solver* durch verschiedenste Fortschritte — insbesondere *Branch-and-Bound*, *Branch-and-Cut* sowie verbesserte Präprozessierungsverfahren — und die gestiegene Rechenleistung moderner Hardware zu effizienten Werkzeugen entwickelt. Moderne *Solver* wie CBC oder Gurobi sind in der Lage, kombinatorische Probleme, die für *Brute-Force* zu komplex sind, in akzeptabler Zeit exakt zu lösen. In dieser Arbeit wird ILP daher als zeitgemäße *Baseline* eingesetzt, die dieselbe Rolle übernimmt wie *Brute-Force* in der Ursprungsarbeit: die Ermittlung des nachweislich optimalen Stundenplans, gegen den die heuristischen Verfahren bewertet werden [27].

Trotz der enormen Fortschritte moderner ILP-*Solver* gibt es Problemklassen, bei denen auch exakte Verfahren an ihre Grenzen stoßen — etwa wenn die Problemgröße weiter wächst, Echtzeit-Anforderungen bestehen oder die Modellierung als ILP nicht praktikabel ist. In solchen Fällen bieten heuristische Verfahren eine Alternative.

2.3.3 Heuristische Verfahren als schnelle, nicht exakte Lösungsverfahren

Heuristische Verfahren verzichten auf die Garantie, das globale Optimum zu finden, und tauschen diese Garantie gegen deutlich kürzere Laufzeiten ein. Anstatt den gesamten Lösungsraum systematisch zu durchsuchen, navigieren sie durch den Suchraum anhand von problemspezifischen Faustregeln oder lokalen Verbesserungsschritten — mit dem Ziel, in akzeptabler Zeit eine möglichst gute, wenn auch nicht notwendigerweise optimale Lösung zu finden. In der *Timetabling*-Literatur haben sich dabei zwei grundlegende Klassen etabliert: *Greedy*-Verfahren und Lokale Suchheuristiken.

Greedy-Konstruktionsheuristiken bauen eine Lösung von Grund auf schrittweise auf, indem sie bei jedem Schritt lokal die beste verfügbare Entscheidung treffen — ohne spätere Schritte zu berücksichtigen. Der Vorteil: Sie sind einfach und schnell; der Nachteil ist, dass frühe Entscheidungen nicht revidiert werden und so zu suboptimalen Gesamtlösungen führen können (lokale Optima). Eine verbreitete Erweiterung ist das *Backtracking*, das lokalen Optima nachträglich auflöst. Der *Offering-Order*-Algorithmus von Feldman und Golumbic [12] folgt genau diesem Prinzip: Er sortiert Offerings nach ihrer Bewertung und wählt sie sequenziell aus, ergänzt um eine *Backtracking*-Strategie für den Fall von Konflikten. Eine weitere bekannte *Greedy*-Konstruktionsheuristik im *Timetabling*-Kontext ist der *Graph-Coloring*-Ansatz [19], bei dem Kurse als Knoten eines Graphen modelliert werden und Konflikte als Kanten — das Stundenplanproblem wird damit auf ein Färbungsproblem reduziert.

Lokale Suchheuristiken hingegen starten von einer bestehenden, oft *greedy* konstruierten Lösung und verbessern sie iterativ durch kleine, gezielte Änderungen. Sie sind in der Lage, initial schlechte Lösungen schrittweise zu verbessern, laufen jedoch ebenfalls Gefahr, in lokalen Optima stecken zu bleiben. Fortgeschrittenere lokale Suchheuristiken versuchen, das Problem lokaler Optima zu umgehen. *Tabu Search* [1] führt eine Verbotsliste kürzlich besuchter Lösungen, um Zyklen zu vermeiden und den Suchraum breiter zu erkunden. *Simulated Annealing* [18] erlaubt mit einer zu Beginn hohen, schrittweise sinkenden Wahrscheinlichkeit auch verschlechternde Schritte, um lokalen Optima zu entkommen. Evolutionäre Algorithmen wie Genetische Algorithmen [1] kombinieren mehrere Lösungen durch *Crossover*- und Mutationsoperatoren und simulieren damit einen evolutionären Selektionsprozess.

Die vorliegende Arbeit untersucht mit *Hill-Climbing* und *Offering-Order* zwei der grundlegendsten Vertreter von *Greedy*-Konstruktionsheuristiken und prüft, ob ihre Ergebnisse unter heutigen Bedingungen Bestand haben — und ob *ILP-Solver* diese Heuristiken mittlerweile auch in der Laufzeit

übertreffen.

Die Frage, unter welchen wissenschaftlichen Anforderungen ein solcher Vergleich durchgeführt werden soll und was es bedeutet, Ergebnisse einer früheren Arbeit unter neuen Bedingungen zu überprüfen, wird im folgenden Kapitel geklärt.

2.4 Replikationsarbeit

Unter einer Replikationsarbeit versteht man den Versuch, Ergebnisse einer früheren Studie durch eine Wiederholung mit demselben oder einem sehr ähnlichen Design zu bestätigen oder zu widerlegen. Replikationsarbeiten gelten als „cornerstone of the scientific method“ [28], weil oft wiederholte, konsistente Ergebnisse das Vertrauen in die wissenschaftliche Aussagekraft stärken. Ziel solcher Arbeiten ist es, die Verlässlichkeit (Reliabilität) und Gültigkeit (Validität) von wissenschaftlichen Erkenntnissen zu prüfen und sicherzustellen, dass veröffentlichte Ergebnisse nicht auf Zufall oder Fehler der ursprünglichen Arbeit beruhen [29].

Reliabilität von Ergebnissen ist gegeben, wenn die Messung bei Wiederholung unter gleichen Bedingungen stabile Werte liefert. Zentrale Aspekte hierbei sind unter anderem [30]:

- Test-Retest-Reliabilität (Konsistenz über Zeit)
- Interne Konsistenz (Kohärenz von Messelementen)
- Interrater-Reliabilität (Übereinstimmung zwischen unterschiedlichen Beobachtern)

Validität ist gegeben, wenn die Messungen auch wirklich das gemessen haben, was gemessen werden sollte. Eine invalide Messung liegt beispielsweise vor, wenn die Mathekompetenz gemessen werden soll, die Textaufgaben allerdings zu kompliziert formuliert sind, sodass es mehr auf Sprachverständnis als Mathematik ankommt.

Hohe Validität setzt in der Regel ausreichende Reliabilität voraus, geht aber darüber hinaus, indem sie fordert, dass die Messwerte inhaltlich sinnvoll interpretierbar sind [31].

In computergestützter Forschung wird unter Reproduzierbarkeit zusätzlich die Möglichkeit verstanden, die Ergebnisse auf Basis der zugrunde liegenden Daten und Algorithmen exakt nachzuvollziehen. Sandve et al. formulierten hierfür zehn Prinzipien („Ten Simple Rules for Reproducible Computational Research“) [14], die von der Dokumentation aller Auswertungsschritte bis zur öffentlichen Zugänglichkeit von Code und Ergebnissen reichen und so die Überprüfbarkeit sicherstellen.

2.4.1 Definition und Arten der Replikation

In der Literatur wird häufig zwischen verschiedenen Arten der Replikation unterschieden, wobei die Terminologie je nach Disziplin variiert. Ein zentraler Unterschied besteht zwischen der „exakten“ oder „nahen“ Replikation (*Close Replication*) und der „konzeptionellen“ Replikation.

- Bei der **exakten Replikation** wird versucht, die Methoden und Prozeduren der Originalstudie so exakt wie möglich zu reproduzieren. Das Ziel ist es, idealerweise nur jene Unterschiede zuzulassen, die unvermeidbar sind (z. B. ein anderer Zeitpunkt oder eine andere Stichprobe aus derselben Population).
- **Konzeptionelle Replikationen und Erweiterungen** überprüfen die Robustheit der Ergebnisse unter veränderten Rahmenbedingungen, beispielsweise durch die Verwendung neuer Datensätze, variierten Parameter oder alternativer Schätzverfahren. Bonett [32] bezeichnet dies auch als *comparable follow-up study*, bei der zwar das gleiche Design und die gleichen Messskalen verwendet werden, aber die Population oder der Kontext variieren kann.

2.4.2 Anforderungen an eine wissenschaftliche Replikation

Damit eine Replikationsarbeit wissenschaftlichen Standards genügt, müssen bestimmte Anforderungen erfüllt sein. Brandt et al. [33] entwickelten hierfür das *Replication Recipe*, welches unter anderem folgende Kriterien hervorhebt:

- **Exakte Definition der zu replizierenden Methoden:** Die Methoden der Originalstudie müssen sorgfältig analysiert und so getreu wie möglich nachgebildet werden.
- **Hohe statistische Aussagekraft:** Die Replikationsstudie muss über eine ausreichende Stichprobengröße verfügen, um Effekte zuverlässig nachweisen zu können.
- **Transparenz und vollständige Dokumentation:** Alle Details zur Durchführung, inklusive Code und Daten, sollten verfügbar gemacht werden, um eine Überprüfung durch Dritte zu ermöglichen.
- **Kritischer Vergleich:** Die Ergebnisse der Replikation müssen statistisch fundiert mit denen der Originalstudie verglichen werden, anstatt sich rein auf Signifikanztests zu verlassen.

Im Bereich der Management-Mathematik und Optimierung wird außerdem gefordert, dass Algorithmen so spezifiziert sind, dass unabhängige Forschende dieselben Ergebnisse erzielen können. Burman et al. [13] betonen weiters die Notwendigkeit, dass der replizierende Forschende unabhängig von den ursprünglichen Autoren ist.

Die vorliegende Bachelorarbeit ordnet sich als Replikationsstudie der Arbeit von Feldman und Golumbic [12] ein. Sie kann als konzeptionelle Replikation mit Erweiterung klassifiziert werden.

3 Zielsetzung und Abgrenzung

Die vorliegende Bachelorarbeit hat zum Ziel, die beschriebene Problemstellung unter den aktuellen technischen Rahmenbedingungen mithilfe verschiedener Lösungsansätze zu untersuchen, diese anhand eines aktuellen Datensatzes zu validieren und anschließend einem Leistungsvergleich zu unterziehen.

1. **Validierung:** Im Mittelpunkt steht die exakte Nachprogrammierung der Algorithmen von Feldman und Golumbic [12]. Es soll überprüft werden, ob diese Verfahren unter modernen Rechenbedingungen und anhand realer Daten aus dem Vorlesungsverzeichnis der Wirtschaftsuniversität Wien in der Lage sind, einen optimalen Semesterplan zu erstellen.
2. **Vergleichende Leistungsanalyse:** Die implementierten Algorithmen werden hinsichtlich der Qualität der erreichten Lösungen (*Score*), ihrer Geschwindigkeit sowie ihres Speicherbedarfs systematisch miteinander verglichen.

Folgende Aspekte sind explizit vom Forschungsumfang ausgeschlossen:

1. Das Problem wird ausschließlich als *Single Student Scheduling* für einen einzelnen Studierenden gelöst. Es wird **keine Rücksicht auf andere Studierende**, die maximale Kapazität von Räumen, die Verfügbarkeit von Lehrenden oder die allgemeine universitäre Ressourcenplanung genommen.
2. Die Entwicklung einer **voll funktionsfähigen Applikation** zur Dateneingabe, Speicherung von Planungen, oder komplexer Visualisierung wird ausgeschlossen. Das Ergebnis des Programms wird durch ein computerlesbares Format (JSON) ausgegeben.

3. Die Planung beschränkt sich auf **ein einzelnes Semester** des Hauptstudiums Wirtschaftsinformatik.
4. Als Hauptstudium Wirtschaftsinformatik werden im Rahmen dieser Arbeit alle verpflichtend zu absolvierenden Lehrveranstaltungen des *Common Body of Knowledge* (CBK) sowie die Pflichtlehrveranstaltungen des Studienzweigs Wirtschaftsinformatik gemäß Studienplan des Bachelorstudiums Wirtschafts- und Sozialwissenschaften der Wirtschaftsuniversität Wien [16, S. 13f] bezeichnet. Explizit ausgeschlossen sind alle optionalen Bestandteile — also Wahlfächer, freie Wahlfächer und Wahlpflichtfächer —, die Studieneingangs- und Orientierungsphase (StEOP) sowie Lehrveranstaltungen anderer Studienzweige. Dieser Umfang entspricht dem Datensatz, der für die Evaluation der in dieser Arbeit implementierten Algorithmen verwendet wurde.

4 Datenbereitstellung

Um einen möglichst aktuellen Datensatz zu erzeugen, wurden die Vorlesungsdaten aus dem Vorlesungsverzeichnis der Wirtschaftsuniversität Wien [34] automatisiert ausgelesen (siehe Kapitel 4.2). Jedem Kurs (*Offering*) ist eine Lehrveranstaltungs-ID zugewiesen, welche durch eine Zahl von 1 bis 9999 dargestellt wird. Weiters gehört jeder Kurs einem Planpunkt (*Course*) an.

4.1 Datenstruktur

Der Datensatz des Vorlesungsverzeichnisses der Wirtschaftsuniversität Wien für das Sommersemester 2025 bildet die Grundlage für die vorliegende Arbeit. Die Daten wurden automatisiert unter Verwendung des beschriebenen Prozesses 1 extrahiert.

Die Modellierung des Studiums an der WU basiert auf zwei zentralen Entitäten, die für das Verständnis der Optimierungsalgorithmen wichtig sind:

- ***Course* (Planpunkt):** Ein *Course* repräsentiert ein zu absolvierendes Modul, das mit einer festen ECTS-Anzahl assoziiert ist. Aus den verfügbaren *Offerings* eines Planpunkts darf maximal eines ausgewählt werden.
- ***Offering* (Lehrveranstaltung):** Ein *Offering* ist eine Lehrveranstaltung, die einem Planpunkt angehört. Jedes *Offering* besitzt eine eindeutige ID (von 1 – 9999) und ist mit konkreten Termin- und Zeitangaben hinterlegt, die für die Prüfung von zeitlichen Konflikten verwendet wird.




Abbildung 2: UML Klassendiagramm des Vorlesungsverzeichnis-Modells

4.2 Extraktionsprozess

Der Prozess der automatisierten Extraktion wurde folgendermaßen realisiert:

Algorithm 1 Datenextraktion aus Vorlesungsverzeichnis

```
1:  $offerings \leftarrow \emptyset$ 
2:  $courses \leftarrow \emptyset$ 
3: for  $id \leftarrow 1, 9999$  do
4:    $url \leftarrow \text{CRAFTCOURSEURL}(id)$ 
5:    $page \leftarrow \text{HTTPGET}(url)$ 
6:   if  $\text{CONTAINS}(page, \text{"Keine Lehrveranstaltung gefunden"})$  then
7:     continue
8:   end if
9:    $(course, dates) \leftarrow \text{EXTRACTDATES}(page)$ 
10:  if  $course \notin \text{dom}(courses)$  then
11:     $ects \leftarrow \text{EXTRACTECTSFROMCOURSE}(course)$ 
12:     $courses \leftarrow courses \cup \{(course, ects)\}$ 
13:  end if
14:   $offerings \leftarrow offerings \cup \{(id, dates, courses_{course})\}$ 
15: end for
```

Das Ergebnis sieht wie folgt aus:

offeringId	dates	lvLeiter	moduleIds	ects
5877	[{"start": "2025-03-11 09:00", "end": "2025-03-11 11:00"}, ...]	Assoz.Prof PD Dr. Sabrina Kirrane	6590	5
6427	[{"start": "2025-03-13 16:30", "end": "2025-03-13 20:30"}, ...]	Dr. Robert Kosik	5160	6
4676	[{"start": "2025-05-06 14:30", "end": "2025-05-06 17:00"}, ...]	Dr. Stefan Treitl	6012	4
6295	[{"start": "2025-03-06 08:00", "end": "2025-03-06 12:00"}, ...]	Anna-Lena Klug, MSc. MSc.	5155	8
5745	[{"start": "2025-03-10 18:00", "end": "2025-03-10 20:00"}, ...]	Dr. Reinhard Zuba	5108	4
6258	[{"start": "2025-04-01 14:00", "end": "2025-04-01 19:00"}, ...]	Dr. Nikolaus Obwegeser	5162	3
5944	[{"start": "2025-05-08 09:30", "end": "2025-05-08 12:00"}, ...]	Univ.Prof. Dr. Jonas Puck	5107	4
5724	[{"start": "2025-03-10 16:00", "end": "2025-03-10 20:00"}, ...]	Alexander Oberreiter, M.Sc.	5105	8
5752	[{"start": "2025-05-06 12:00", "end": "2025-05-06 14:30"}, ...]	Univ.Prof. Dipl.Wirtsch.-Math.Dr. Birgit Rudloff	6023	4
6354	[{"start": "2025-05-06 15:30", "end": "2025-05-06 18:00"}, ...]	Zhenyi Wang, M.Sc.	5059	4
6447	[{"start": "2025-03-13 12:30", "end": "2025-03-13 16:30"}, ...]	Anita Neumannova, PhD, MSc (WU), MIM (CEMS)	5161	4
5329	[{"start": "2025-09-01 14:00", "end": "2025-09-01 17:00"}, ...]	Dr. Tingmingke Lu	5056	4
6317	[{"start": "2025-03-05 14:00", "end": "2025-03-05 18:00"}, ...]	Dipl.-Wirt.-Ing.(FH) Mark Nicolas Grünsteidl	5158	8
6130	[{"start": "2025-05-06 09:30", "end": "2025-05-06 12:00"}, ...]	Jana Hlavinova, Ph.D.	6024	4
6182	[{"start": "2025-03-11 10:00", "end": "2025-03-11 12:00"}, ...]	Dr. Sonja Sperber	5136	3
6089	[{"start": "2025-09-10 09:00", "end": "2025-09-10 13:00"}, ...]	Dr. Nikolai Neumayer	5106	4
4086	[{"start": "2025-05-06 14:30", "end": "2025-05-06 17:00"}, ...]	Vanessa Kofler, LL.M. (WU)	5109	4
5762	[{"start": "2025-03-10 16:30", "end": "2025-03-10 18:00"}, ...]	Univ.Prof. Jonas Bunte, Ph.D.	5117	4

Tabelle 1: Auszug des Ergebnisses der Datenbereitstellung

4.3 Deskriptive Analyse

Um die Komplexität des Datensatzes und des Optimierungsproblems zu quantifizieren, wurde eine deskriptive Analyse durchgeführt. In der Analyse wurden nur *Offerings* aus dem Hauptstudium Wirtschaftsinformatik des Bachelor Wirtschafts- und Sozialwissenschaften im Sommersemester 2025 berücksichtigt.

Der vollständige Datensatz besteht aus insgesamt 381 *Offerings* ($|\mathcal{O}|$) und 28 *Courses*, woraus sich eine durchschnittliche Anzahl von 13,6 *Offerings* pro *Course* ergibt. Eine genauere Analyse zeigt, dass die *Offerings* sehr ungleichmäßig verteilt sind: Während die Mehrheit der *Courses* (über 50 %) zwei oder drei Angebote aufweist, gibt es einzelne Ausreißer mit bis zu 44 Angeboten. Diese starke Rechtsschiefe der Verteilung zeigt, dass der statistische Mittelwert durch wenige, sehr angebotsintensive *Courses* nach oben verzerrt wird, während der Median deutlich unter dem Durchschnitt liegt.

Abbildung 3 zeigt die Verteilung der *Offerings* auf die *Courses*.




Abbildung 3: Verteilung der *Offerings* pro *Course*

Ein wesentlicher Faktor für die Schwierigkeit der Stundenplanerstellung ist die zeitliche Ungleichverteilung der angebotenen Kurse. Abbildung 4 zeigt die Verteilung der Lehrveranstaltungen über die Wochentage.




Abbildung 4: Verteilung der Kurse auf Wochentage

Wie aus den Daten ersichtlich wird, konzentriert sich der Großteil des Lehrangebots (ca. 88 %) auf die Kernzeit von Montag bis Donnerstag, während der Freitag mit 11,3 % bereits deutlich seltener belegt ist. Samstage spielen im regulären Lehrbetrieb nahezu keine Rolle. Diese ungleiche Verteilung verschärft die Problematik zeitlicher Überschneidungen ($\mathcal{F}_{Zeit}$) an Tagen mit besonders vielen Kursen.

Zusätzlich zur Verteilung auf die Tage ist die zeitliche Platzierung innerhalb eines Tages entscheidend für die Modellierung von Präferenzen. Abbildung 5 schlüsselt die Startzeiten der einzelnen Kurseinheiten auf. Der Einfachheit halber werden angefangene Stunden bis 15 Minuten abgerundet und ab 30 Minuten aufgerundet. Vorlesungen beginnen ausschließlich im 15-Minuten-Takt. Aus den Daten geht hervor, dass Kurseinheiten unter der Woche zwischen 8:00 und 21:00 Uhr sowie samstags zwischen 9:00 und 15:00 Uhr stattfinden.




Abbildung 5: Verteilung der Kurs-Startzeiten (in Prozent)

Die Analyse der Startzeiten zeigt, dass die WU Wien ein sehr breites Zeitfenster nutzt. Ein signifikanter Anteil der Kurse beginnt bereits um 08:00 Uhr (15,6 %), was für Studierende mit Präferenzen für einen späteren Vorlesungsbeginn (vgl. Szenario 5.4.1) eine hohe Anzahl an potenziell zu vermeidenden Einheiten bedeutet.

Neben dem Beginn der Einheiten variiert auch die Dauer der einzelnen Termine, was die Berechnung von Überschneidungsfreiheiten komplexer gestaltet als bei starren Zeitslots. Abbildung 6 stellt die Dauer der Einheiten dar.




Abbildung 6: Verteilung der Terminlänge der Buchungsstunden in 15-Minuten-Intervallen

Die überwiegende Mehrheit der Veranstaltungen (79,1 %) dauert zwischen zwei und vier Stunden.

5 Analyse

5.1 Implementierung des ILP Baseline Ansatzes

Feldman und Golumbic vergleichen in ihrem Paper [12] die Outputs der Algorithmen *Hill-Climbing* und *Offering-Order* mit dem optimalen Stundenplan, der mittels *Brute-Force* ermittelt wurde. Da ein *Brute-Force* Algorithmus bei der großen Anzahl der Vorlesungen im VVZ der WU eine zu lange Laufzeit hätte, wurde eine *Integer Linear Programming* (ILP) Lösung als Benchmark gewählt, die ebenfalls unter Berücksichtigung aller Nebenbedingungen den optimalen Stundenplan erzeugt [15].

5.1.1 Variablen, Parameter und Zielfunktion

Zur formalen Definition des Modells werden die folgenden Mengen, Parameter und Entscheidungsvariablen verwendet:

- **Mengen:**

- $\mathcal{O}$: Menge aller verfügbaren Kursangebote (*Offerings*).
- $\mathcal{D}$: Menge aller Kalendertage, an denen Kurse stattfinden.
- $\mathcal{G}$: Menge der Kursgruppen (z. B. verschiedene Parallelveranstaltungen desselben Kurses).
- $\mathcal{G}_g \subseteq \mathcal{O}$: Teilmenge der Angebote, die zur Gruppe $g \in \mathcal{G}$ gehören.
- $\mathcal{D}_d \subseteq \mathcal{O}$: Teilmenge der Angebote, die Termine am Kalendertag $d \in \mathcal{D}$ haben.
- $\mathcal{F}_{\text{Zeit}}$: Menge aller Paare (i, j) von Angeboten, die eine zeitliche Überschneidung aufweisen.
- $\mathcal{M}_{\text{Muss}}, \mathcal{M}_{\text{Blockiert}} \subseteq \mathcal{O}$: Mengen von Angeboten, die zwingend gewählt bzw. ausgeschlossen werden müssen.

- **Parameter:**

- $\text{Mark}(i)$: Der berechnete Nutzen für das Kursangebot i .
- $C_{\min}, C_{\max}$: Unter- und Obergrenze für die Gesamtzahl der zu wählenden Kurse.
- $D_{\min}, D_{\max}$: Unter- und Obergrenze für die Anzahl der Kurse an einem belegten Tag.

- **Entscheidungsvariablen:**

- $y_i \in \{0, 1\}$: Binäre Variable; 1 wenn Kursangebot i gewählt wird, sonst 0.
- $u_d \in \{0, 1\}$: Binäre Hilfsvariable; 1 wenn am Tag d mindestens ein Kurs belegt wird, sonst 0.

Mathematische Formulierung des ILP-Modells

$$\text{maximiere: } \sum_{i \in \mathcal{O}} \text{Mark}(i) \cdot y_i \quad (1)$$

unter den Nebenbedingungen:

$$\sum_{i \in \mathcal{O}} y_i \geq C_{\min} \quad (2)$$

$$\sum_{i \in \mathcal{O}} y_i \leq C_{\max} \quad (3)$$

$$\sum_{i \in \mathcal{G}_g} y_i \leq 1 \quad \forall g \in \mathcal{G} \quad (4)$$

$$\sum_{i \in \mathcal{D}_d} y_i \geq D_{\min} \cdot u_d \quad \forall d \in \mathcal{D} \quad (5)$$

$$\sum_{i \in \mathcal{D}_d} y_i \leq D_{\max} \cdot u_d \quad \forall d \in \mathcal{D} \quad (6)$$

$$y_i + y_j \leq 1 \quad \forall (i, j) \in \mathcal{F}_{\text{Zeit}} \quad (7)$$

$$y_i = 1 \quad \forall i \in \mathcal{M}_{\text{Muss}} \quad (8)$$

$$y_i = 0 \quad \forall i \in \mathcal{M}_{\text{Blockiert}} \quad (9)$$

$$y_i, u_d \in \{0, 1\} \quad \forall i \in \mathcal{O}, \forall d \in \mathcal{D} \quad (10)$$

Abbildung 7: Mathematische Formulierung des ILP-Modells zur Stundenplanoptimierung

5.1.2 Nebenbedingungen (Constraints)

- **Anzahl der Lehrveranstaltungen** (Gleichungen 2 und 3): Begrenzen die Gesamtzahl der gewählten Lehrveranstaltungen, wobei $C_{\min}$ und $C_{\max}$ die definierten Mindest- bzw. Maximalanzahlen darstellen.
- **Gruppen-Beschränkung** (Gleichung 4): Stellt sicher, dass aus jeder vordefinierten Gruppe $g \in \mathcal{G}$ (verschiedene *Offerings* desselben Kurses) maximal eine Lehrveranstaltung ausgewählt wird.
- **Tägliche Kursanzahl** (Gleichungen 5 und 6): Regelt die Anzahl der Kurse pro Kalendertag $d \in \mathcal{D}$. Durch die binäre Hilfsvariable u_d wird sichergestellt, dass an einem Tag entweder gar kein Kurs ($u_d = 0$) oder eine Anzahl zwischen $D_{\min}$ und $D_{\max}$ ($u_d = 1$) belegt wird.
- **Zeitliche Überschneidungen** (Gleichung 7): Verhindert die gleichzeitige Auswahl von Lehrveranstaltungen, deren Termine sich zeitlich überschneiden. Die Menge $\mathcal{F}_{\text{Zeit}}$ enthält alle Paare (i, j) , die einen Konflikt verursachen.
- **Feste Zuordnungen** (Gleichungen 8 und 9):
 1. $\mathcal{M}_{\text{Muss}}$ (8): Erzwingt die Auswahl von Lehrveranstaltungen, die als zwingend notwendig (Priorität = 100) definiert sind.
 2. $\mathcal{M}_{\text{Blockiert}}$ (9): Verbietet die Auswahl von Lehrveranstaltungen, die nicht gewählt werden dürfen (Priorität = -100).

Durch das Lösen dieses Modells wird ein optimaler Satz an Entscheidungsvariablen y_i (Stundenplan) bestimmt, der die Zielfunktion (*Mark*) maximiert, während alle Nebenbedingungen erfüllt werden. Das Ergebnis ist der optimal mögliche Stundenplan gemäß der definierten *Constraints*.

5.1.3 Beispielimplementierung in Python

Die in Kapitel 5.1.1 und 5.1.2 formal beschriebenen Variablen, Zielfunktion und Nebenbedingungen werden in Python mithilfe der Bibliothek *PuLP* umgesetzt. *PuLP* ermöglicht es, ILP-Modelle deklarativ zu formulieren und an einen externen *Solver* — in diesem Fall den quelloffenen *CBC-Solver* [35] — zu übergeben. Die vollständige Implementierung ist im zugehörigen Repository [15] einsehbar. Im Folgenden werden die zentralen Modellbestandteile anhand von Codeauszügen erläutert.

Modellinitialisierung, Entscheidungsvariablen und Zielfunktion

Zunächst wird das Maximierungsproblem als `LpProblem`-Objekt angelegt. Für jedes verfügbare Kursangebot $i \in \mathcal{O}$ wird eine binäre Entscheidungsvariable $y_i \in \{0, 1\}$ definiert, die angibt, ob das Angebot in den Stundenplan aufgenommen wird. Die Zielfunktion entspricht Gleichung 1: Die Summe $Mark(i) \cdot y_i$ wird maximiert.

```
1 model = pulp.LpProblem("CourseSelection", pulp.LpMaximize)
2
3 # Entscheidungsvariable  $y_i$  fuer jedes Offering  $o$  in  $\mathcal{O}$ 
4 y = {
5     o.offeringId: pulp.LpVariable(f"y_{o.offeringId}",
6                                   cat="Binary")
7 }
8
9 # Zielfunktion: maximiere Summe  $Mark(i) \cdot y_i$ 
10 model += pulp.lpSum(
11     Mark(o) * y[o.offeringId] for o in offerings
12 )
```

Listing 1: Modellinitialisierung und Zielfunktion

Feste Zuordnungen und Kursanzahl

Angebote aus $\mathcal{M}_{\text{Muss}}$ (hier beispielhaft die *Offerings* mit den Identifikatoren „1234“ und „1235“) werden gemäß Gleichung 8 durch eine Gleichheitsbedingung $y_i = 1$ erzwungen. Die Gleichungen 2 und 3 schränken die Gesamtzahl der gewählten Kurse auf das Intervall $[C_{\min}, C_{\max}]$ ein (Der Stundenplan in diesem Beispiel darf zwischen 3 und 5 *Offerings* umfassen).

```
1 # Gleichung 8: M_Muss - zwingend zu wählende Offerings
2 for must_id in ["1234", "1235"]:
3     model += y[must_id] == 1
4
5 # Gleichungen 2 und 3: C_min <= Summe y_i <= C_max
6 model += (
7     pulp.lpSum(y[o.offeringId] for o in offerings)
8     >= 3
9 )
10 model += (
11     pulp.lpSum(y[o.offeringId] for o in offerings)
12     <= 5
13 )
```

Listing 2: Feste Zuordnungen und Kursanzahl

Planpunkt-Beschränkung

Gleichung 4 stellt sicher, dass pro Planpunkt $c \in \mathcal{C}$ — also pro *Course* mit mehreren *Offerings* — höchstens ein *Offering* ausgewählt wird. Dazu werden die *Offerings* zunächst nach ihrer *courseId* gruppiert, woraufhin für jeden Planpunkt eine entsprechende Ungleichung ergänzt wird.

```
1 # Courses aufbauen: courseId -> Liste von offeringIds
2 course_map = defaultdict(list)
3 for o in offerings:
4     course_map[o.courseId].append(o.offeringId)
5
6 # Gleichung 4: Summe y_i <= 1 fuer jeden Course c in C
7 for courseId, offeringIds in course_map.items():
8     model += pulp.lpSum(y[offeringId] for offeringId in
9                           offeringIds) <= 1
```

Listing 3: Gruppen-Beschränkung

Tägliche Auslastung

Die binäre Hilfsvariable $u_d \in \{0,1\}$ zeigt an, ob an Tag d überhaupt Kurse belegt werden. Analog zu den Gleichungen 5 und 6 wird die maximale Stundenanzahl pro Tag nach unten mit $D_{\min} \cdot u_d$ und nach oben mit $D_{\max} \cdot u_d$ begrenzt. In diesem Beispiel belegt ein Studierender an einem gegebenen Tag entweder keine Kurse oder Kurse im Ausmaß von mindestens 3 und maximal 8 Stunden.

```
1 # u_d: binaere Hilfsvariable fuer Tag d
2 u_d = pulp.LpVariable(f"used_day_{day}", cat="Binary")
3
4 # Gewichtete Stundensumme fuer diesen Tag
5 day_hour_sum = pulp.lpSum(
6     y[cid] * hrs for cid, hrs in contributions
7 )
8
9 # Gleichung 5: D_min * u_d <= Tagesauslastung
10 model += day_hour_sum >= 3 * u_d
11
12 # Gleichung 6: Tagesauslastung <= D_max * u_d
13 model += day_hour_sum <= 8 * u_d
```

Listing 4: Tägliche Auslastung

Zeitliche Überschneidungen

Zur Umsetzung von Gleichung 7 werden die *Offerings* zunächst nach Kalendertag gruppiert, sodass ausschließlich *Offerings* desselben Tages auf zeitliche Überschneidungen geprüft werden. Damit entfallen Vergleiche zwischen *Offerings* verschiedener Tage — etwa zwischen einem Montags- und einem Freitagstermin — die keinen Konflikt erzeugen können. Für jeden Tag werden alle Zeitpunkte, zu denen Kurse beginnen oder enden, als Trennpunkte herangezogen, und für jeden entstehenden Zeitslot wird geprüft, welche Angebote in diesen fallen. Sind es mehr als eines, wird eine Bedingung ergänzt, die verhindert, dass mehr als ein *Offering* dieses Slots gleichzeitig gewählt wird. Dies reduziert die Anzahl der generierten *Constraints* und beschleunigt Modellaufbau und -lösung.

```

1 timeline = defaultdict(list)
2 for o in offerings:
3     for date_info in o.dates:
4         start = date_info["start"]
5         end = date_info["end"]
6         day = start.date()
7         timeline[day].append((start, end, o.offeringId))
8
9 for day, sessions in timeline.items():
10     # Alle Zeitpunkte des Tages als Trennpunkte sammeln
11     times = sorted(set(
12         [s[0] for s in sessions] + [s[1] for s in sessions]
13     ))
14
15     for i in range(len(times) - 1):
16         slot_start, slot_end = times[i], times[i + 1]
17
18         # Alle Offerings, die in diesen Slot fallen
19         active_vars = [
20             y[offeringId]
21             for start, end, offeringId in sessions
22             if start < slot_end and end > slot_start
23         ]
24
25         # Constraint: max. ein Offering pro Zeitslot
26         if len(active_vars) > 1:
27             model += (
28                 pulp.lpSum(active_vars) <= 1,
29                 f"overlap_{day}_{i}"
30             )

```

Listing 5: Zeitliche Überschneidungen

5.1.4 CPU vs. GPU

Um der technologischen Entwicklung seit der Veröffentlichung der ursprünglichen Algorithmen Rechnung zu tragen, wurde die ILP-Lösung sowohl für CPU- als auch für GPU-Architekturen (NVIDIA CUDA) implementiert [15]. Das ermöglicht eine Bewertung der Rechenzeit unter modernen Bedingungen, die über die Möglichkeiten der ursprünglichen Studie hinausgehen.

5.2 Implementierung der Hill-Climbing Algorithmen

Basierend auf der Methodik von Feldman und Golumbic [12] wurden die Optimierungsalgorithmen *Hill-Climbing v1* und *Hill-Climbing v3* implementiert. Das Ziel dieser Algorithmen ist es, inkrementell, durch lokal optimale Entscheidungen einen Stundenplan zu finden, der die Zielfunktion (*Mark*) maximiert.

5.2.1 Hill-Climbing v1

Der *Hill-Climbing v1*-Algorithmus wählt bei jedem Schritt das beste verfügbare *Offering* aus **allen verfügbaren Offerings** gemessen am *Mark* des Stundenplans inklusive des gewählten *Offering* [15].

5.2.2 Hill-Climbing v3

Der *Hill-Climbing-v3*-Algorithmus unterscheidet sich vom *v1*-Ansatz dadurch, dass der Suchraum für einen neuen Kurs reduziert wird. Anstatt alle verfügbaren *Offerings* zu evaluieren, beschränkt *v3* die Auswahl auf eine Teilmenge der nach *Mark* sortierten Liste. Konkret wird in der Implementierung nur die zweite Hälfte — die Offerings mit der individuell besten *Mark* — der verfügbaren *Offerings* betrachtet [15].

5.2.3 Suchstrategie

Ausgehend vom aktuellen Stundenplan wird für jeden möglichen nächsten Zustand die *Mark* berechnet, indem der Stundenplan ergänzt um ein weiteres *Offering* durch die Evaluationsfunktion bewertet wird. Anschließend wird jenes Lehrangebot ausgewählt, das zu der höchsten Bewertung führt, und in den Stundenplan übernommen.

$$a^* = \arg \max_{a \in \text{available_offerings}} (\text{Mark}(\text{schedule} \cup \{a\})) \quad (11)$$

Nur jene *Offerings* werden in die Auswahl aufgenommen, die keine Nebenbedingungen verletzen (zeitliche Überschneidung, Planpunkt bereits erfüllt, *Offering* bereits gewählt, *Offering* in Liste verbotener Kurse). Die Schleife wird fortgesetzt, solange ein gültiges *Offering* gefunden wird, das zu einer Verbesserung oder Erweiterung des Stundenplans führt.

5.2.4 Abbruchkriterien

Der Algorithmus bricht ab, wenn einer der folgenden Zustände eintritt:

1. Der Stundenplan ist valide und hat die maximale Anzahl von Lehrveranstaltungen erreicht.
2. Der Stundenplan ist valide, und es kann keine weitere gültige *Offering* gefunden werden, ohne dass eine Nebenbedingung verletzt wird.
3. Es kann kein weiteres *Offering* gefunden werden, das keine *Constraints* verletzt. Wenn die minimale Anzahl der Lehrveranstaltungen noch nicht erfüllt ist, führt das zu einem ungültigen Ergebnis.

Algorithm 2 Hill-Climbing

```

1: schedule  $\leftarrow \emptyset$ 
2: availableOfferings  $\leftarrow \text{FILTERCONFLICTS}(\text{offerings})$ 
3: while availableOfferings  $\neq \emptyset$  do
4:   nextOffering  $\leftarrow \arg \max_{o \in \text{availableOfferings}} \text{MARK}(\text{schedule} \cup \{o\})$ 
5:   if  $\text{ISVALID}(\text{schedule} \cup \{\text{nextOffering}\})$  then
6:     schedule  $\leftarrow \text{schedule} \cup \{\text{nextOffering}\}$ 
7:   end if
8:   if  $|\text{schedule}| = \text{MAXSCHEDULELENGTH}$  then
9:     return schedule
10:  end if
11:  availableOfferings  $\leftarrow \text{FILTERCONFLICTS}(\text{offerings})$ 
12: end while
13: return schedule

```

5.2.5 Zur Nicht-Implementierung von Hill-Climbing v2

Der von Feldman und Golumbic vorgeschlagene *Hill-Climbing v2*-Algorithmus priorisiert zusätzlich auf der Ebene von Gruppen (*Groups*). Im Originalkontext des Papers beziehen sich Gruppen auf die Unterscheidung zwischen Pflichtveranstaltungen (*Mandatory*) und Wahlveranstaltungen (*Elective*), wobei die Priorität der Gruppen die Auswahl von Pflichtveranstaltungen vor Wahlveranstaltungen erzwingt [12]. Zwar sieht der Studienplan des Bachelorstudiums Wirtschafts- und Sozialwissenschaften der WU grundsätzlich Wahlveranstaltungen vor. Der im Rahmen dieser Arbeit verwendete Datensatz beschränkt sich jedoch explizit auf die Pflichtlehrveranstaltungen des Hauptstudiums Wirtschaftsinformatik (vgl. Kapitel 3, Punkt 4) — Wahlfächer, freie Wahlfächer und Wahlpflichtfächer sind bewusst ausgeschlossen. Die für *v2* essentielle Unterscheidung zwischen Pflicht- und Wahlgruppen ist im vorliegenden Datensatz daher strukturell nicht vorhanden: Alle *Offerings* gehören derselben Prioritätskategorie an, weshalb die Implemen-

tierung von $v2$ funktional identisch mit $v1$ wäre und keine zusätzlichen Erkenntnisse liefern würde. Da $v1$ und $v3$ aufgrund des unterschiedlich großen Suchraums bereits einen aussagekräftigeren Vergleich ermöglichen, wurde auf die Implementierung von $v2$ verzichtet.

5.3 Implementierung des Offering-Order Algorithmus

Basierend auf der Methodik von Feldman und Golumbic [12] wurde der Optimierungsalgorithmus *Offering-Order* implementiert, der auf einer heuristischen Sortierung basiert.

5.3.1 Sortierung

Der Algorithmus nutzt die berechneten *Marks*, um eine Suchreihenfolge festzulegen:

1. Alle *Offerings* innerhalb desselben Planpunkts werden absteigend nach *Mark* sortiert. Innerhalb eines Planpunkts wird somit das Offering mit dem höchsten *Mark* zuerst in Betracht gezogen.
2. Die Planpunkte selbst werden nach dem *Mark* des besten *Offering* innerhalb des Planpunkts sortiert.

5.3.2 Suchstrategie

Der optimale Stundenplan wird durch eine *Forward-Checking Backtracking* Strategie gesucht. Es wird folgendermaßen vorgegangen:

1. Die Planpunkte werden iterativ durchlaufen. Gestartet wird mit dem Planpunkt, der das *Offering* mit der höchsten *Mark* beinhaltet (siehe 5.3.1).
2. Für jeden Planpunkt wird versucht, das *Offering* mit der höchsten *Mark* auszuwählen. Bevor die Auswahl getroffen wird, wird geprüft, ob das Hinzufügen des *Offerings* zu dem aktuellen Teilstundenplan zu einer zeitlichen Überschneidung führt oder andere *Constraints* verletzt (*Forward-Checking*).
3. Führt das Hinzufügen eines *Offerings* zu keinem gültigen Endergebnis in den nachfolgenden Planpunkten, wird die Auswahl rückgängig gemacht und das nächstbeste *Offering* der aktuellen Gruppe wird getestet (*Backtracking*).

Algorithm 3 Offering-Order Algorithm

```
1: schedule  $\leftarrow \emptyset$ 
2:  $i \leftarrow 0$ 
3: loop
4:   select an offering  $o \in \text{groups}_i$ 
5:   if there is no  $o$  then
6:     backtrack to preceding state
7:   else
8:     schedule  $\leftarrow \text{schedule} \cup \{o\}$ 
9:     for all  $\text{groups}_j (i < j \leq n)$  do
10:      remove from  $\text{groups}_j$  all violating offers
11:    end for
12:    if any  $\text{groups}_j$  becomes empty then
13:      backtrack to preceding state
14:    else
15:       $i \leftarrow i + 1$ 
16:      if  $i = n$  then
17:        return schedule
18:      end if
19:    end if
20:  end if
21: end loop
```

5.4 Szenariendefinition

Die Szenarien wurden als isolierte Testfälle konzipiert, um eine kontrollierte Vergleichbarkeit zwischen den Algorithmen zu gewährleisten; eine Kombination mehrerer Szenarien ist durch die zugrundeliegende *Constraint*-Architektur technisch möglich, wurde jedoch bewusst ausgeklammert.

Um die beschriebenen Algorithmen unter realistischen Bedingungen zu testen, wurden folgende Szenarien definiert:

5.4.1 Freier Tag

Laut einer Umfrage an der Hochschule Trier gaben 81% der Studierenden an, gerne einen komplett freien Tag zu haben, um einem Nebenjob nachzugehen. 13% der Studierenden gaben an, jeden Tag erst um 9:45 Uhr beginnen zu wollen, und 6% möchten einen oder mehrere freie Vormittage haben. Dabei wurde am häufigsten der Freitag (31%) vor dem Montag (6%) gewünscht. 64% der Studierenden wäre es egal, welchen Tag sie freibekommen [3]. Aus diesen Ergebnissen wurden folgende Szenarien abgeleitet:

- Keine Kurse an Montagen
- Keine Kurse an Freitagen
- Jeder Tag der Woche bis 9:45 frei
- Keine Kurse an Donnerstagen und Freitagen

5.4.2 Beliebte Zeiten

Laut einer weiteren Umfrage [4] bevorzugen 74% der Studierenden Prüfungen und Kurse, die über das Semester verteilt stattfinden. Teilt man den Tag in die drei Zeitslots Vormittag, Nachmittag und Abend ein, so war der Nachmittag der beliebteste Zeitslot, gefolgt vom Vormittag und dem Abend. Aus diesen Ergebnissen wurden folgende Szenarien abgeleitet:

- Erhöhte Priorität (+90) für Nachmittags, negative Priorität (−90) für Abend
- Erhöhte Priorität (+70) für Vormittag, neutrale Priorität (0) für Nachmittag, negative Priorität (−80) für Abend

5.4.3 Ähnliche Problemstellungen

Hinzu kommen klassische *Constraints*, die in *University-Course-Timetabling*-Problemen häufig vorkommen [1]. Diese *Constraints* betreffen meist die universitäre Planung des Curriculums und die Zuteilung von Kursen zu Räumen, es gibt jedoch auch *Constraints*, die die Erstellung individueller Stundenpläne der Studierenden betreffen:

- Studierende müssen von 12:00 bis 13:00 Zeit für ein Mittagessen haben
- Pro Tag werden entweder keine oder mindestens 3 Stunden Vorlesungen besucht
- Pro Tag dürfen nicht mehr als 8 Stunden Vorlesungen besucht werden

5.4.4 Vergleichbarkeit

Zusätzlich zu den oben genannten *Constraints* sollen die Algorithmen auch in Extremfällen hinsichtlich ihrer Performance getestet werden. Daher werden ergänzend folgende Szenarien definiert, die in verwandten Arbeiten nicht explizit untersucht wurden, jedoch zur Vergleichbarkeit zwischen den Algorithmen sinnvoll sind:

- Alle Kurse können frei von *Constraints* gewählt werden.
- 25% - 75% aller Kurse können nicht belegt werden.
- 1 - 7 Kurse sind vorgegeben
- Keine Kurse zwischen 6:00 morgens und 13:00.
- Keine Kurse Montags, Dienstags und Mittwochs

5.5 Versuchsaufbau

Das Paper von Feldman und Golumbic [12] wählte einen *Brute-Force*-Algorithmus als *Baseline* für Performance-Vergleiche. Da ein *Brute-Force*-Algorithmus bei der großen Anzahl der Vorlesungen im VVZ der WU eine zu lange Laufzeit hätte, wurde eine *Integer Linear Programming* (ILP) Lösung als neue *Baseline* gewählt. Diese gewährleistet, ebenso wie der *Brute-Force*-Ansatz für kleine Instanzen, die Ermittlung des optimalen Stundenplans (mit der höchsten *Mark*). Die Ergebnisse der heuristischen Algorithmen (*Hill-Climbing v1*, *Hill-Climbing v3*, *Offering-Order*) werden folglich relativ zur optimalen Lösung des ILP-Ansatzes bewertet. Zusätzlich zu den heuristischen Algorithmen wird auch eine GPU-optimierte Variante des ILP-Ansatzes getestet.

Als Maß für die Schwierigkeit (*Difficulty*) der Probleminstanz wird in dieser Arbeit nicht die Laufzeit des *Brute-Force*-Algorithmus verwendet, sondern die Anzahl der zu planenden Kurse (N).

Die Algorithmen wurden anhand der folgenden Leistungskennzahlen evaluiert:

1. **Mark**: Die Qualität der gefundenen Lösung (in Prozent relativ zum *Baseline*-Ansatz).
2. **Laufzeit**: Die zur Lösungsfindung benötigte Zeit.
3. **Speicherbedarf**: Der benötigte Hauptspeicher.

5.5.1 Zielfunktion

Die *Mark* dient als Bewertungsfunktion für die Qualität eines erstellten Stundenplans und entspricht der im Paper von Feldman und Golumbic [12] definierten Zielfunktion. Sie quantifiziert, wie gut ein Stundenplan die Präferenzen und *Constraints* der Studierenden erfüllt. Die Berechnung erfolgt ausschließlich für **gültige** Stundenpläne, d. h. solche, die keine restriktiven *Constraints* ($|p| = P$) verletzen.

Jede Präferenz oder Restriktion ist im Modell durch eine *Priorität* p im Wertebereich $[-P, P]$ definiert. Positive Prioritäten kennzeichnen wünschenswerte Eigenschaften (z. B. bevorzugte Lehrveranstaltungen oder Zeitfenster), negative Prioritäten hingegen unerwünschte. Die Stärke des Präferenzwerts ist proportional zum Absolutwert der Priorität.

Die *Mark* eines gültigen Stundenplans S ergibt sich aus der Summe der positiven Beiträge durch gewählte Kurse und den Abzügen für Verletzungen sogenannter *Fixed*- und *Non-Fixed-Constraints*:

$$Mark(S) = \underbrace{\sum_{c \in C_S} q_c}_{\text{Kursprioritäten}} - \underbrace{\sum_{h \in H_{\text{violated}}^{(f)}} |p_h^{(f)}|}_{\text{Strafen für Fixed-Constraints}} - \underbrace{\sum_{t \in T_{\text{violated}}^{(n)}} v_t \cdot |p_t^{(n)}|}_{\text{Strafen für Non-Fixed-Constraints}}, \quad (12)$$

wobei gilt:

- C_S : Menge aller im Stundenplan S enthaltenen Kurse.
- q_c : Priorität des Kurses c .
- $H_{\text{violated}}^{(f)}$: Menge aller Stunden, in denen ein *Fixed Constraint* verletzt wurde.
- $p_h^{(f)}$: Priorität der Stunde h . Eine Verletzung liegt vor, wenn
 - $p_h^{(f)} < 0$ und die Stunde aktiv ist (der Studierende hat in einer ungewünschten Stunde Unterricht), oder
 - $p_h^{(f)} > 0$ und die Stunde inaktiv ist (der Studierende hat in einer gewünschten Stunde keinen Unterricht).
- $T_{\text{violated}}^{(n)}$: Menge der verletzten *Non-Fixed Constraints*.
- $p_t^{(n)}$: Priorität des *Constraint* t .
- v_t : Anzahl der verletzten Stunden (bzw. des Zeitumfangs), der durch *Constraint* t betroffen ist.

Je höher der Wert von $Mark(S)$, desto besser erfüllt der Stundenplan die angegebenen Präferenzen. Ziel der Optimierungsalgorithmen ist daher die Maximierung von $Mark(S)$.

5.5.2 Durchführung

Die experimentelle Evaluation der Algorithmen erfolgte durch systematische Benchmarks, die Performance und Lösungsqualität der implementierten Ansätze unter verschiedenen Szenarien und Schwierigkeitsgraden testen.

Die Experimente wurden auf einem GPU-Server der Wirtschaftsuniversität Wien durchgeführt. Die Hardware-Infrastruktur hat folgende Spezifikationen:

- **Prozessor:** AMD EPYC 9334

- **Arbeitsspeicher:** 128 GB RAM
- **Grafikkarte (ILP GPU):** Zwei NVIDIA RTX A5000 GPUs (jeweils 24 GB VRAM) mit CUDA 12.4
- **Betriebssystem:** Ubuntu/Debian via Proxmox Kernel (6.8.12-11-pve)

Um eine verlässliche und gleichbleibende Testumgebung zu garantieren, wurde das Tool *benchexec* genutzt. Jeder Testlauf hatte ein Zeitlimit von 10 Sekunden und lief auf einem Prozessorkern. Um die Ergebnisse nicht zu verfälschen, wurde der Server während der Tests nicht anderweitig verwendet.

Die Algorithmen wurden in 14 verschiedenen Szenarien getestet. Jedes Szenario stellt eine vorkonfigurierte Zusammensetzung von *Constraints* dar (definiert in JSON-Konfigurationsdateien, z.B. `constraint1.json`).

Der Schwierigkeitsgrad (*Difficulty*) einer Probleminstanz wird durch die Anzahl der zu planenden Kurse N definiert, im Gegensatz zur Laufzeit des *Brute-Force*-Algorithmus, die in der Originalarbeit verwendet wurde. Die Tests wurden inkrementell für jede mögliche Kursanzahl N , beginnend bei $N = 1$ bis zur maximal möglichen Kursanzahl im jeweiligen Szenario, durchgeführt. Die maximale Kursanzahl wurde dabei vorab mithilfe des ILP-*Baseline*-Ansatzes ermittelt.

Für jeden Algorithmus ($A \in \{ILP, ILP\ GPU, Offering-Order, Hill-Climbing\ v1, Hill-Climbing\ v3\}$), für jede Kursanzahl N und für jedes Szenario S wurde die Messreihe wie folgt durchgeführt:

1. Jeder Algorithmus wurde für eine feste Kursanzahl $N = 50$ Mal unabhängig voneinander ausgeführt.
2. Die 50 Messungen pro Algorithmus und Schwierigkeitsgrad wurden sequenziell durchgeführt, um sicherzustellen, dass die Messergebnisse für die Laufzeit und den Speicherbedarf unabhängig sind.
3. Es wurden folgende Metriken für jede der 50 Ausführungen erfasst:
 - Laufzeit (t): Die zur Lösungsfindung benötigte Zeit (in Sekunden).
 - Hauptspeicher (M): Der während der Ausführung belegte Hauptspeicher (in Megabyte).
 - Qualität ($Mark$)
4. Für die 50 Messwerte der Laufzeit und des Hauptspeichers wurden folgende statistische Kennzahlen berechnet:
 - Median ($t_{\text{median}}, M_{\text{median}}$)

- Mittelwert ($t_{\text{mean}}, M_{\text{mean}}$)
- Minimalwert ($t_{\text{min}}, M_{\text{min}}$)
- Maximalwert ($t_{\text{max}}, M_{\text{max}}$)
- Standardabweichung ($t_{\text{stdev}}, M_{\text{stdev}}$)


Um die Algorithmen vergleichbar zu halten, wurde der gemessene Zeit- und Speicherbedarf auf die Ausführung des Algorithmus selbst begrenzt. Das *Preprocessing* — insbesondere die Vorabberechnung der *Mark* für jedes *Offering*, die einmalig vor der Hauptschleife durchgeführt wird — ist nicht in den Messwerten enthalten.

6 Ergebnisse


Im Folgenden werden die Benchmark-Ergebnisse präsentiert. Für das erste Szenario wird ein vollständiger Ergebnissatz aufgeführt (*Mark*, Laufzeit, Hauptspeicher und VRAM). Bei allen nachfolgenden Ergebnissen werden ausschließlich relevante Abweichungen hervorgehoben. Sämtliche Diagramme sind in Kapitel 9 zu finden.

6.1 Szenario 1: Keine Kurse an Montagen


Bis Schwierigkeitsstufe 10 findet *Offering-Order* stets den optimalen Stundenplan und erreicht konstant 100 % des ILP-Optimums. *Hill-Climbing v1* und *v3* liefern in diesem Bereich gleichwertige Ergebnisse: Bei den Stufen 1–3 erzielen beide ebenfalls 100 %, sinken jedoch bis Stufe 9 leicht auf 96–97 % ab und bleiben damit durchgehend hinter *Offering-Order*. Ab Schwierigkeitsstufe 10 divergieren die beiden Varianten: *Hill-Climbing v1* hält sich bei den Stufen 11 und 12 stabil bei rund 94 %, während *Hill-Climbing v3* von 95 % bei Stufe 10 auf 90 % bei Stufe 11 und weiter auf ca. 88 % bei Stufe 12 abfällt und bei Stufe 13 keine gültige Lösung mehr findet. Die Lösungsqualität von *Offering-Order* bricht ab Schwierigkeitsstufe 10 deutlich ein — von 100 % auf ca. 90 % — und fällt damit unter jene von *Hill-Climbing v1*.




Bis Schwierigkeitsstufe 10 steigen die Laufzeiten von *Hill-Climbing v1* und *v3* gleichmäßig an — von jeweils rund 0,1 s bei Stufe 1 auf ca. 0,9 s bei Stufe 10. ILP weist mit konstant ca. 0,35 s eine höhere, aber stabile Laufzeit auf, die selbst bei niedrigen Schwierigkeitsgraden über jener der *Hill-Climbing*-Varianten liegt. ILP GPU steigt im selben Bereich von 0,07 s auf 0,5 s an. *Offering-Order* bleibt bis Stufe 10 konstant bei ca. 0,17 s und ist damit der schnellste Algorithmus. Auffällig ist, dass ab Schwierigkeitsstufe 10 die Laufzeiten — mit Ausnahme von *Hill-Climbing v1* — zurückgehen: *Hill-Climbing v3* sinkt von 0,9 s auf 0,6 s, ILP von 0,35 s auf 0,2 s, und *Offering-Order* besonders stark von 0,18 s auf 0,05 s.



Bis Schwierigkeitsgrad 10 ist die Hauptspeichernutzung aller Algorithmen konstant, jedoch auf deutlich unterschiedlichen Niveaus: ILP CPU belegt stabil ca. 1,3 MB und *Offering-Order* ca. 2,3 MB, während *Hill-Climbing v1*, *Hill-Climbing v3* und ILP GPU mit jeweils ca. 35 KB deutlich darunter liegen. Ab Schwierigkeitsgrad 10 verschiebt sich dieses Bild: Die Speichernutzung von ILP GPU steigt auf ca. 1,3 MB an und nähert sich damit dem Niveau von ILP CPU, während *Offering-Order* auf ca. 35 KB fällt. Alle übrigen Algorithmen bleiben stabil.




Die VRAM-Auslastung von ILP GPU beträgt über alle gemessenen Schwierigkeitsstufen konstant ca. 14 Gigabyte.




6.2 Szenario 2: Keine Kurse an Freitagen


Die Lösungsqualität von *Hill-Climbing v1* und *v3* entwickelt sich bis Schwierigkeitsgrad 10 identisch: Ausgehend von 100 % bei den Stufen 1–3 sinkt sie kontinuierlich auf ca. 94 % bei Stufe 10. Ab Schwierigkeitsgrad 11 divergieren die beiden Varianten — *Hill-Climbing v3* fällt auf 88 %, während *Hill-Climbing v1* mit 89 % leicht besser abschneidet. *Offering-Order* liegt über alle Schwierigkeitsstufen hinweg unter beiden *Hill-Climbing*-Varianten und sinkt von 95 % bei Stufe 2 auf ca. 86 % bei Stufe 13.



Die Laufzeiten von *Hill-Climbing v1* und *v3* steigen mit zunehmender Schwierigkeit an: *Hill-Climbing v1* wächst von 0,15s bei Stufe 1 auf bis zu 0,95s bei den Stufen 12–14, *Hill-Climbing v3* von 0,1s auf 0,58s bei den Stufen 10–13. *Offering-Order* bleibt durchgehend der schnellste Algorithmus und hält sich stabil zwischen 0,08s bei Stufe 1 und 0,06s bei Stufe 13. ILP CPU und ILP GPU weisen konstante, aber höhere Laufzeiten auf — ca. 0,30s bzw. 0,67s —, wobei die Laufzeit von ILP CPU ab Schwierigkeitsgrad 6 leicht zwischen 0,33s und 0,69s schwankt.




Die Hauptspeicherauslastung ist in diesem Szenario über alle Schwierigkeitsstufen hinweg konstant. ILP CPU belegt mit ca. 4 MB den höchsten Speicherbedarf, gefolgt von ILP GPU mit ca. 2,1 MB. *Hill-Climbing v1*, *Hill-Climbing v3* und *Offering-Order* belegen mit ca. 40 KB, 33 KB bzw. 26 KB deutlich weniger Speicher.




6.3 Szenario 3: Jeder Tag der Woche bis 9:45 frei

Die Ergebnisse verlaufen weitgehend analog zu den vorigen Szenarien. Bemerkenswert ist, dass *Hill-Climbing v3* trotz des reduzierten Suchraums zwischen den Schwierigkeitsstufen 4 und 7 bessere Stundenpläne generiert als *Hill-Climbing v1*: *Hill-Climbing v3* hält in diesem Bereich konstant 100 %, während *Hill-Climbing v1* auf 98–99 % absinkt. Ab Stufe 7 kehrt sich dieses Verhältnis um — bei Stufe 12 etwa erzielt *Hill-Climbing v1* 94 % gegenüber 90 % bei *Hill-Climbing v3*. Auffällig ist zudem, dass *Offering-Order* bei Schwierigkeitsstufe 14 mit 94 % einen besseren Stundenplan erzeugen konnte als *Hill-Climbing v1* mit 92 %.




6.4 Szenario 4: Keine Kurse an Donnerstagen und Freitagen

Auch hier verhalten sich die Ergebnisse weitgehend analog zu den vorherigen Szenarien. Auffällig ist, dass *Hill-Climbing v1* und *v3* über alle Schwierigkeitsstufen hinweg identische Ergebnisse liefern. *Offering-Order* hält gut mit, liegt bei einzelnen Schwierigkeitsgraden jedoch leicht darunter: bei Stufe 4 etwa 95 % gegenüber 99 %, bei Stufe 6 93 % gegenüber 95 %, bei Stufe 7 94 % gegenüber 95 % und bei Stufe 9 91 % gegenüber 92,5 %. Interessant ist, dass *Offering-Order* bei Schwierigkeitsgrad 11 noch eine gültige Lösung mit 89 % findet, während die *Hill-Climbing*-Varianten an dieser Stelle bereits scheitern.




6.5 Szenario 5: Erhöhte Priorität (+90) für Nachmittag, negative Priorität (-90) für Abend

Bis Schwierigkeitsstufe 5 erreichen alle heuristischen Algorithmen das optimale Ergebnis von 100 %. Danach setzt eine Staffelung ein: *Hill-Climbing v1* liefert die längste Lösungsserie — bis Stufe 16 hält es ca. 95 %, bevor es bei Stufe 17 auf 88 % abfällt. *Hill-Climbing v3* produziert bis Stufe 9 stabile 99 %, sinkt dann jedoch kontinuierlich und erreicht bei Stufe 15 noch 87 %. *Offering-Order* zeigt ein volatileres Bild: Bei Stufe 6 fällt die *Mark* auf 85 % und erreicht bei Stufe 9 mit 70 % ihren niedrigsten Wert, bevor sie sich bei den Stufen 11–15 auf ca. 88 % erholt. Bei Stufe 16 fällt *Offering-Order* erneut auf 72 % und findet ab Stufe 17 keine gültige Lösung mehr.




Das Laufzeitverhalten ähnelt jenem aus Szenario 2. ILP zeigt bis Schwierigkeitsstufe 13 eine stabile Laufzeit von ca. 0,55 s, steigt danach jedoch kontinuierlich an und erreicht bei Stufe 17 ca. 2 s. *Hill-Climbing v1* wächst von unter 1 s bei den Stufen 1–2 auf ca. 3 s ab Stufe 9 und verbleibt auf diesem Niveau. *Hill-Climbing v3* bleibt bis Stufe 6 unter 1 s und stabilisiert sich ab Stufe 10 bei ca. 1,3 s. ILP GPU ist mit 1,1–1,2 s konstant. *Offering-Order* läuft bis Stufe 15 stabil bei ca. 0,17 s, schnellst bei Stufe 16 auf 7,4 s hoch und überschreitet bei Stufe 17 das Zeitlimit.




6.6 Szenario 6: Erhöhte Priorität (+70) für Vormittag, neutrale Priorität (0) für Nachmittag, negative Priorität (-80) für Abend

Auffällig ist, dass *Hill-Climbing v3* und *Offering-Order* ab Schwierigkeitsstufe 14 noch gültige Lösungen finden, während *Hill-Climbing v1* an dieser Stelle bereits keine Ergebnisse mehr produziert. Gleichzeitig bleibt die Lösungsqualität von *Hill-Climbing v1* in diesem Szenario durchgehend hoch und fällt nie unter 95 %. *Hill-Climbing v3* hingegen bewegt sich zwischen den Stufen 8 und 13 im Bereich von 90–95 %, fällt bei Stufe 14 auf 75 % und bei Stufe 15 auf 60 %. *Offering-Order* findet bei Stufe 15 noch eine Lösung mit 72 %, schwankt aber bei den Stufen 16 und 17 zwischen 58 % und 62 %.




Das Laufzeitverhalten ähnelt jenem aus Szenario 2. *Hill-Climbing v1* steigt von 0,5s bei Stufe 1 auf ca. 5s ab Stufe 9, wo es sich stabilisiert. ILP GPU bleibt konstant bei ca. 1,2s, während ILP CPU von 0,5s bei Stufe 1 auf maximal 1,3s bei Stufe 16 ansteigt. *Offering-Order* hält bis Schwierigkeitsstufe 14 eine stabile Laufzeit von ca. 0,26s, steigt dann jedoch stark an — auf 0,5s bei Stufe 15, 4s bei Stufe 16 und 7s bei Stufe 17 — und überschreitet bei Stufe 18 das Zeitlimit. Dieser starke Anstieg lässt sich auf häufiges *Backtracking* zurückführen, das ein *Brute-Force*-ähnliches Suchverhalten nach sich zieht.




6.7 Szenario 7: Studierende müssen von 12:00 bis 13:00 Zeit für ein Mittagessen haben

Hill-Climbing v3 erzeugt zwischen den Schwierigkeitsstufen 6 und 10 trotz eingeschränktem Suchraum bessere Stundenpläne als *Hill-Climbing v1*: In diesem Bereich hält *Hill-Climbing v3* konstant 100 %, während *Hill-Climbing v1* auf 98 % abfällt. Bei höheren Schwierigkeitsstufen verbessern sich die Ergebnisse von *Offering-Order* zunehmend: Nach einem Tiefpunkt von 78 % bei Stufe 5 steigt die Qualität kontinuierlich auf 92 % bei Stufe 13 und verbleibt auf diesem Niveau.




Auch die Laufzeiten verlaufen ähnlich wie in Szenario 2. *Hill-Climbing v1* steigt von 0,3 s bei Stufe 1 auf ca. 3 s bei Stufe 9 und verbleibt auf diesem Niveau. *Hill-Climbing v3* wächst von 0,2 s auf 2 s bei Stufe 10 und stabilisiert sich dort. ILP CPU und ILP GPU sind mit ca. 0,22 s bzw. 0,38 s konstant, wobei ILP GPU leicht höhere Laufzeiten aufweist. Bemerkenswert ist, dass die Laufzeit von *Offering-Order* mit steigender Schwierigkeitsstufe sogar leicht abnimmt: von 0,17 s bei den Stufen 2–8 auf 0,13 s bei den Stufen 9–14 und schließlich 0,1 s bei den Stufen 15–17.




6.8 Szenario 8: Studierende müssen mehr als einen Kurs pro Tag besuchen


Die Qualität der erstellten Stundenpläne schwankt in diesem Szenario stark. *Hill-Climbing v1* und *v3* liefern bis Schwierigkeitsgrad 6 gleichwertige Ergebnisse, die zwischen 100 % bei Stufe 1 und 67 % bei Stufe 6 schwanken. Bei Schwierigkeitsgrad 7 liegt *Hill-Climbing v1* mit 89 % knapp vor *Hill-Climbing v3* mit 88 %. *Offering-Order* zeigt das volatilste Verhalten: Die Qualität startet bei 70 % bei Stufe 1 und schwankt in der Folge zwischen 69 % bei Stufe 8 und 98 % bei Stufe 7.



Die Laufzeiten von ILP und ILP GPU schwanken in diesem Szenario erheblich: ILP bewegt sich zwischen 0,1 s bei Stufe 5 und 5,7 s bei Stufe 8, ILP GPU zwischen 1,2 s bei Stufe 1 und 6,7 s bei Stufe 5. *Hill-Climbing v1* und *v3* steigen moderat an — von 0,04 s bzw. 0,03 s bei Stufe 1 auf 0,14 s bzw. 0,09 s bei Stufe 7. *Offering-Order* bleibt bis Schwierigkeitsgrad 8 konstant bei 0,13 s und steigt erst bei Schwierigkeitsgrad 9 auf 0,6 s an.




Der Hauptspeicherbedarf von ILP schwankt in diesem Szenario stark: Im Regelfall belegt ILP ca. 8,4 MB, fällt jedoch bei Schwierigkeitsstufe 5 auf 38 KB und bei Stufe 7 auf 700 KB ab. ILP GPU bewegt sich zwischen 4,2 MB und 8,4 MB. *Hill-Climbing v1*, *Hill-Climbing v3* und *Offering-Order* sind mit 15–23 KB, 23–33 KB bzw. 29–41 KB konstant auf niedrigem Niveau.




6.9 Szenario 9: Studierende dürfen nicht mehr als drei Kurse pro Tag besuchen

Die Lösungsqualität von *Hill-Climbing v1* und *v3* ist bis Schwierigkeitsstufe 13 gleichwertig: Ausgehend von 100 % bei Stufe 1 sinkt sie kontinuierlich auf 96 % bei Stufe 13 ab. Danach erzielt *Hill-Climbing v1* leicht bessere Ergebnisse — bei Stufe 16 etwa 95 % gegenüber 94 % bei *Hill-Climbing v3*. *Offering-Order* liegt über alle Schwierigkeitsstufen hinweg unter den *Hill-Climbing*-Varianten und erreicht bei den Stufen 8 und 9 mit 88 % seinen niedrigsten Wert, der damit als einziger unter die 90 %-Marke fällt. Generell ist die Lösungsqualität in diesem Szenario sehr gut.




Die Laufzeit von ILP CPU steigt kontinuierlich von 0,3 s bei Stufe 1 auf 1,8 s bei Stufe 17, sodass ab Stufe 14 ILP GPU mit konstant ca. 1 s die kürzeren Laufzeiten aufweist. *Hill-Climbing v1* und *v3* steigen ebenfalls mit der Schwierigkeit an — von 0,2 s bzw. 0,1 s bei Stufe 1 auf 2 s bzw. 1 s bei Stufe 17. *Offering-Order* bleibt mit ca. 0,1 s konstant auf dem niedrigsten Niveau aller Algorithmen.




6.10 Szenario 10: Alle Kurse können frei von Constraints gewählt werden

Die Qualität der Stundenpläne ist mit jener aus Szenario 9 vergleichbar. Die Lösungsqualität von *Hill-Climbing v1* und *v3* ist bis Schwierigkeitsstufe 13 gleichwertig: Ausgehend von 100 % bei Stufe 1 sinkt sie kontinuierlich auf 96 % bei Stufe 13 ab. Danach erzielt *Hill-Climbing v1* leicht bessere Ergebnisse — bei Stufe 16 etwa 95 % gegenüber 94 % bei *Hill-Climbing v3*. *Offering-Order* liegt über alle Schwierigkeitsstufen hinweg unter den *Hill-Climbing*-Varianten und erreicht bei den Stufen 8 und 9 mit 88 % seinen niedrigsten Wert, der damit als einziger unter die 90 %-Marke fällt. Generell ist die Lösungsqualität in diesem Szenario sehr gut.




Die Laufzeit von ILP CPU steigt kontinuierlich von 0,3 s bei Stufe 1 auf 1,8 s bei Stufe 17, sodass ab Stufe 14 ILP GPU mit konstant ca. 1 s die kürzeren Laufzeiten aufweist. *Hill-Climbing v1* und *v3* steigen ebenfalls mit der Schwierigkeit an — von 0,2 s bzw. 0,1 s bei Stufe 1 auf 2 s bzw. 1 s bei Stufe 17. *Offering-Order* bleibt mit ca. 0,1 s konstant auf dem niedrigsten Niveau aller Algorithmen.




6.11 Szenario 11: 25% – 75% aller Kurse können nicht belegt werden

Beide *Hill-Climbing*-Varianten erzielen über alle Schwierigkeitsstufen hinweg identische Ergebnisse: Ausgehend von 100 % bei Stufe 1 sinkt die Lösungsqualität kontinuierlich auf 94 % bei Stufe 15. *Offering-Order* liegt ab Schwierigkeitsgrad 2 durchgehend darunter und bewegt sich zwischen den Stufen 4 und 15 im Bereich von 85–90 %.




Die Laufzeiten von *Hill-Climbing v1* und *v3* steigen kontinuierlich mit der Schwierigkeit: *Hill-Climbing v1* wächst von 0,13 s bei Stufe 1 auf 1,2 s bei Stufe 15, *Hill-Climbing v3* von 0,09 s auf 0,7 s. *Offering-Order* bleibt bis Schwierigkeitsgrad 14 konstant bei ca. 0,07 s und steigt bei Stufe 15 deutlich auf 0,4 s an — womit es über alle Stufen der schnellste Algorithmus ist. ILP GPU ist mit ca. 0,7 s konstant. ILP CPU zeigt bis Schwierigkeitsgrad 6 eine stabile Laufzeit von ca. 0,36 s und steigt danach leicht auf 0,5–0,6 s an.




6.12 Szenario 12: 1 – 7 Kurse sind vorgegeben

Offering-Order zeigt in diesem Szenario besonders schwache Leistungen: Bei Stufe 1 erreicht der Algorithmus noch 100 %, fällt bei Stufe 2 jedoch abrupt auf 30 % und hält sich bei den Stufen 3 und 4 bei ca. 27 %, bevor er ab Schwierigkeitsstufe 5 das Zeitlimit überschreitet und keine Ergebnisse mehr produziert. *Hill-Climbing v1* und *v3* liefern bis Schwierigkeitsstufe 12 gleichwertige Ergebnisse im Bereich von 100 % bis ca. 95 %; danach erzeugt *Hill-Climbing v1* leicht bessere Stundenpläne — bei Stufe 16 etwa 93 % gegenüber 91 % bei *Hill-Climbing v3*.




Die Laufzeiten beider *Hill-Climbing*-Varianten steigen kontinuierlich mit zunehmender Schwierigkeit: *Hill-Climbing v1* wächst von 0,18 s bei Stufe 1 auf 2,7 s bei Stufe 17, *Hill-Climbing v3* von 0,1 s auf 1,3 s bei Stufe 16. *Offering-Order* weist mit konstant 0,13 s stabil geringe Laufzeiten auf, läuft jedoch bereits ab Schwierigkeitsstufe 4 ins Zeitlimit.




6.13 Szenario 13: Keine Kurse zwischen 6:00 Uhr morgens und 13:00 Uhr

Hill-Climbing v3 erzielt in diesem Szenario ab Schwierigkeitsstufe 3 durchgehend bessere Ergebnisse als *Hill-Climbing v1*: Bei den Stufen 1–3 erzielen beide noch 100 %; bei den Stufen 4 und 5 hält *Hill-Climbing v3* 100 %, während *Hill-Climbing v1* bereits zurückfällt. Dieser Vorsprung wächst mit der Schwierigkeit — bei Stufe 10 etwa erreicht *Hill-Climbing v3* 92 %, *Hill-Climbing v1* nur 83 %. Bemerkenswert ist, dass *Hill-Climbing v3* und *Offering-Order* bei Schwierigkeitsstufe 11 noch gültige Lösungen finden, obwohl *Hill-Climbing v1* hier bereits scheitert — und das, obwohl der Suchraum bei *Hill-Climbing v3* eingeschränkt ist. *Offering-Order* bewegt sich bei den Stufen 1–3 bei 100 % und schwankt danach zwischen 82 % (Stufe 10) und 92 % (Stufe 7).




Die Laufzeiten der *Hill-Climbing*-Varianten steigen gleichmäßig mit zunehmender Schwierigkeit: *Hill-Climbing v1* wächst von 0,13 s bei Stufe 1 auf 0,84 s bei Stufe 10, *Hill-Climbing v3* von 0,11 s auf 0,7 s. *Offering-Order* ist die schnellste Heuristik und hält bei den Stufen 1–6 ca. 0,07 s, sinkt bis Stufe 10 sogar leicht auf 0,04 s, bevor es bei Stufe 11 mit 2,4 s einen deutlichen Anstieg verzeichnet.




6.14 Szenario 14: Keine Kurse am Montag, Dienstag und Mittwoch

Offering-Order erzielt in diesem Szenario bei den Schwierigkeitsstufen 7 und 8 noch gültige Lösungen, während *Hill-Climbing v1* und *v3* an dieser Stelle bereits scheitern. *Hill-Climbing v1* erreicht bei den Stufen 1–4 noch 100 % und sinkt bis Stufe 6 auf 94 %, findet danach jedoch keine Lösung mehr. *Hill-Climbing v3* fällt nach 100 % bei den Stufen 1–3 bereits bei Stufe 4 auf 90 % und bei Stufe 5 auf 86 % ab. *Offering-Order* hält bei den Stufen 1–4 ebenfalls 100 %, erreicht bei den Stufen 6 und 7 seinen niedrigsten Wert von 94 % und steigt bei Stufe 8 wieder auf 96 %.



Die Laufzeit von ILP CPU ist mit konstant ca. 0,03 s durchgehend niedriger als jene von ILP GPU mit ca. 0,18 s. *Hill-Climbing v1* steigt von 0,03 s bei Stufe 1 auf 0,07 s bei Stufe 4 und verbleibt dort bis Stufe 6. *Hill-Climbing v3* wächst von 0,03 s auf 0,04 s bei Stufe 2 und stabilisiert sich bis Stufe 5 auf diesem Niveau. *Offering-Order* ist die schnellste Heuristik und läuft konstant bei ca. 0,01 s, verzeichnet bei Schwierigkeitsstufe 8 jedoch einen Anstieg auf 0,18 s.



7 Diskussion

7.1 Ergebnisse in der Ursprungsarbeit

Feldman und Golumbic [12] verglichen in ihrer Arbeit einen *Offering-Order*-Algorithmus mit zwei *Hill-Climbing*-Algorithmen. Sie stellten fest, dass der *Offering-Order*-Algorithmus (insbesondere in der *Update*-Variante, in der die *Mark* nach jeder Auswahl des nächsten Kurses neu berechnet wurde) die *Hill-Climbing*-Ansätze (getestet als Version 2 und 3) in der Lösungsqualität häufig übertrifft oder zumindest gleichwertige Ergebnisse liefert. Hinsichtlich der Laufzeit weist *Offering-Order* eine kürzere Laufzeit als die *Hill-Climbing*-Implementierungen vor. Gemessen wurde die Lösungsqualität als Prozentsatz relativ zum Optimum (welches mittels *Brute-Force* ermittelt wurde). Die Laufzeit wurde in Sekunden gemessen.

7.2 Vergleich mit der Ursprungsarbeit

Die Ergebnisse dieser Bachelorarbeit zeigen sowohl Bestätigungen als auch interessante Abweichungen zu den Erkenntnissen von Feldman und Golumbic [12].

7.2.1 Lösungsqualität (Score)

Ein wesentlicher Unterschied zeigt sich in der Lösungsqualität. Feldman und Golumbic stellten fest, dass der *Offering-Order*-Algorithmus (insbesondere in der *Update*-Variante) den *Hill-Climbing*-Ansatz (getestet als Version 2 und 3) häufig übertrifft oder zumindest gleichwertige Ergebnisse liefert, besonders bei der Berücksichtigung von *Constraints*. In den vorliegenden Ergebnissen zeigt sich aber ein anderes Bild: Die implementierten *Hill-Climbing*-Algorithmen (*v1* und *v3*) erzielten in den meisten Szenarien (z. B. Szenario 1, 2, 4) durchgehend höhere Scores als der *Offering-Order*-Algorithmus. Der *Offering-Order*-Ansatz performte in dieser Arbeit fast durchgehend schlechter als die *Hill-Climbing*-Varianten.

Dieser scheinbare Widerspruch lässt sich erklären: In dieser Arbeit wurde die Variante *Offering-Order - Fixed* implementiert. Ein Blick auf die Daten von Feldman und Golumbic zeigt, dass auch dort die *Fixed*-Variante deutlich volatiler und oft schlechter abschnitt als die *Update*-Variante. Dass der *Offering-Order*-Algorithmus in dieser Arbeit besonders schlecht abschnitt, wenn bereits Kurse vorgegeben waren (Szenario 12), zeigt die Schwäche der statischen Sortierung: Sobald der Suchraum durch fixe Kurse eingeschränkt ist, verläuft sich *Offering-Order* in lokalen Optima, die eine niedrige *Mark*

haben oder die Mindestanzahl an gewählten *Offerings* nicht erfüllt.

Interessant ist außerdem der Vergleich der *Hill-Climbing*-Varianten. Während angenommen werden könnte, dass Version 1 (größerer Suchraum) immer bessere Ergebnisse liefert als Version 3 (reduzierter Suchraum), zeigte sich in Szenario 1 („Keine Kurse an Montagen“), dass *Hill-Climbing v3* teilweise bessere Ergebnisse lieferte als *v1*. Dies deutet darauf hin, dass eine Einschränkung des Suchraums in *v3* nützlich sein kann und den Algorithmus davor bewahrt, sich in seltenen lokalen Optima zu verfangen, die in *v3* vorzeitig eliminiert werden, aber in *v1* aufgrund der breiteren Suche gewählt werden.

7.2.2 Laufzeit und Performance

Hinsichtlich der Laufzeit decken sich die Ergebnisse weitgehend mit der Ursprungsarbeit. Feldman und Golumbic identifizierten *Offering-Order* als schnellste Methode. Das konnte bestätigt werden; *Offering-Order* war in allen Messungen schneller als die *Hill-Climbing*-Ansätze. Auch die Beobachtung, dass *Hill-Climbing v1* aufgrund des größeren Suchraums langsamer ist als *v3*, entspricht den Erwartungen.

Die Ergebnisse hinsichtlich der Laufzeit decken sich mit der Ursprungsarbeit auch unter den veränderten Rahmenbedingungen dieser Replikationsarbeit. Feldman und Golumbic [12] identifizierten *Offering-Order* als die schnellste Methode unter den verglichenen Algorithmen — dies zeigt sich auch im Kontext des realen WU-Datensatzes: *Offering-Order* war in allen 14 Szenarien konsistent schneller als beide *Hill-Climbing*-Varianten. Der Laufzeitvorteil von *Offering-Order* ist damit nicht auf die spezifischen Daten oder Rahmenbedingungen von 1990 beschränkt, sondern erweist sich als robust gegenüber einem neuen Datensatz. Des Weiteren bestätigt sich die Beobachtung, dass *Hill-Climbing v1* aufgrund des größeren Suchraums langsamer ist als *v3* — ein Ergebnis, das sich in dieser Arbeit über alle Szenarien hinweg zeigt und die theoretische Erwartung erfüllt.

7.3 Eigene Ergebnisse im erweiterten Kontext

7.3.1 Der Einfluss moderner Solver (ILP)

Ein Aspekt, den die Ursprungsarbeit von 1990 technologisch bedingt nicht untersuchen konnte, ist der Vergleich mit modernen exakten Verfahren. Feldman und Golumbic nutzten *Brute-Force* als *Baseline* (siehe Kapitel 2.3.1). Durch die begrenzte Rechenleistung waren ILP-*Solver* zur Zeit der Ursprungsarbeit noch keine praktikable Lösung (siehe Kapitel 2.3.2). Die Ergebnisse dieser Arbeit zeigen jedoch, dass moderne ILP-*Solver* (hier:

CBC/Gurobi via Python-MIP) für die betrachteten Problemgrößen extrem effizient sind. Entgegen der Erwartung, dass Heuristiken für diese kombinatorischen Probleme notwendig sind, um — beispielsweise für eine Webanwendung — akzeptable Laufzeiten von maximal 10 Sekunden [24] zu erreichen, war der ILP-Ansatz (CPU) in fast allen Szenarien schneller als die Heuristiken *Hill-Climbing* und *Offering-Order*. Lediglich in Szenario 8 („Mehr als ein Kurs pro Tag“) war die Laufzeit von ILP durchgehend über jenen von *Offering-Order* und *Hill-Climbing*.

7.3.2 GPU vs. CPU

Der Vergleich zwischen CPU- und GPU-basiertem ILP zeigte zudem, dass die GPU-Implementierung zwar sehr konstante Laufzeiten aufweist, jedoch bei kleineren und mittleren Problemgrößen langsamer ist als die CPU-Variante. Erst bei steigender Komplexität steigt auch die Effizienz der GPU, was die CPU-Variante für typische Probleminstanzen zur bevorzugten Wahl macht.

7.4 Einschränkungen

Die Generalisierbarkeit und Gültigkeit der Ergebnisse unterliegt bestimmten Einschränkungen, die bei der Interpretation berücksichtigt werden müssen.

- **Spezifität des Datensatzes:** Die Evaluation erfolgte ausschließlich auf Basis der Daten der Wirtschaftsuniversität Wien für das Sommersemester 2025. Die Struktur dieses Datensatzes (Dichte der Konflikte, Verteilung der Kurse auf Wochentage) beeinflusst die Performance der Algorithmen. An Universitäten mit anderen Wahlmöglichkeiten könnten die Heuristiken (insbesondere *Offering-Order*) andere Ergebnisse liefern.
- **Algorithmen-Varianten:** Wie in Kapitel 5.3 diskutiert, wurde beim *Offering-Order*-Algorithmus die statische Variante (*Fixed*) implementiert. Auf die Implementierung der *Update*-Variante wurde in dieser Arbeit verzichtet. Der Grund hierfür ist derselbe wie für den Verzicht auf *Hill-Climbing v2*: Es fehlen im vorliegenden Kontext die notwendigen Abhängigkeiten (beispielsweise zwischen Pflicht- und Wahlfachgruppen), auf denen diese Varianten basieren. Da diese Abhängigkeiten für die spezifische Logik der *Update*- bzw. *v2*-Varianten essenziell sind, beschränkte sich die Untersuchung auf die Varianten, die ohne diese Abhängigkeiten operieren (*Hill-Climbing v1/v3* und *Offering-Order Fixed*). Eine Implementierung unter Berücksichtigung solcher Abhängigkeiten könnte zu einer anderen Lösungsqualität und Laufzeit führen.

- **Abhängigkeit von Hardware:** Die Laufzeitmessungen wurden auf einem spezifischen Server der Wirtschaftsuniversität Wien durchgeführt. Während die relativen Unterschiede zwischen den Algorithmen übertragbar sein dürften, sind die absoluten Laufzeiten hardwareabhängig. Insbesondere der Break-Even-Point zwischen CPU- und GPU-ILP hängt von der CUDA-Leistung ab.
- **Zielfunktion:** Die Definition der Zielfunktion und die Gewichtung der Penalties sind subjektiv gewählt. Eine Veränderung dieser Parameter verändert die Suchlandschaft. Heuristiken bleiben dementsprechend öfter oder seltener in lokalen Optima stecken.
- **Kombination der Szenarien:** Die Evaluation beschränkt sich auf isolierte Szenarien; obwohl die *Constraint*-Architektur deren Kombination technisch unterstützt, wurde auf eine kombinierte Auswertung verzichtet, um die Vergleichbarkeit der Algorithmen über alle Szenarien hinweg sicherzustellen.

8 Fazit

8.1 Anwendungsfälle und Weiterentwicklung

Die Ergebnisse dieser Arbeit legen nahe, dass ein ILP-basierter Ansatz zur automatisierten Semesterplanung für WU-Studierende aufgrund von Laufzeit und Lösungsqualität die beste Wahl ist. Der naheliegendste Anwendungsfall ist die Integration der entwickelten Algorithmen in bestehende studentische Tools: Der ÖH-WU Studienplaner [5] bietet bereits eine Weboberfläche zur manuellen Prüfung von Überschneidungsfreiheit. Eine Erweiterung um eine automatisierte Stundenplanoptimierung — auf Basis des in dieser Arbeit implementierten ILP-Ansatzes — würde den Mehrwert des Tools steigern, da Studierende nicht mehr manuell kombinieren müssten, sondern einen nach individuellen Präferenzen optimierten Stundenplan erhalten könnten.

Hinsichtlich einer möglichen Weiterentwicklung bietet das ILP-Modell eine solide Grundlage. So ließen sich einerseits die in dieser Arbeit einzeln betrachteten *Constraints* kombinieren, andererseits lassen sich durch die Zielfunktion prinzipiell beliebige weitere Präferenzen modellieren — etwa die Bevorzugung bestimmter Lehrender oder die Berücksichtigung von Gehzeiten zwischen den Gebäuden der WU. Weiters wäre denkbar, das Modell auf einen *Multi-Student-Scheduling* Ansatz zu erweitern, also die simultane Optimierung der Stundenpläne mehrerer Studierender unter Berücksichtigung sozialer Präferenzen wie gemeinsamer Vorlesungen. Um den praktischen Nutzen der Arbeit für Studierende unmittelbar erfahrbar zu machen, wäre ein Web- oder Mobile-Interface der logische nächste Schritt.

8.2 Verwandte Arbeiten

Mit Ausnahme der Ursprungsarbeit von Feldman und Golumbic [12] konnte im Rahmen der Literaturrecherche keine weitere Arbeit identifiziert werden, die das *Scheduling-Problem* aus der Perspektive eines einzelnen Studierenden behandelt; alle übrigen gefundenen Arbeiten adressieren institutionelle Planungsprobleme auf Ebene des UCTTP oder des SSP. Diese 18 verwandten Arbeiten werden im Folgenden entlang von vier Dimensionen eingeordnet: Problem, Lösungsverfahren, Datenbasis und zentrale Erkenntnisse.

Student Sectioning (SSP): Akbarzadeh & Maenhout [36] lösen die Zuweisung von Medizinstudierenden zu Krankenhausstationen mit *Branch-and-Price* (exakt) — der Algorithmus zerlegt das Problem in kleinere Teilprobleme und löst sie systematisch. Getestet an synthetischen Instanzen der Uni

Gent (bis 80 Studierende). Fairness und Präferenzen konnten gleichzeitig optimiert werden. Zanazzo et al. [37] greifen dasselbe Problem auf, nutzen aber *Simulated Annealing* (Metaheuristik) — eine Methode, die zufällig Lösungen verbessert und dabei bewusst auch schlechtere Lösungen akzeptiert, um nicht in lokalen Optima stecken zu bleiben. Mit bis zu 320 Studierenden findet der Ansatz dieselbe Qualität wie das exakte Verfahren — aber in einem Bruchteil der Rechenzeit (2,5 bis 48,2 Sekunden bei SA vs. 8.054 Sekunden bei MIP). Heitmann & Brüggemann [38] lösen das SSP der Uni Hamburg (3.735 Studierende, 300 Gruppen, 48 Kurse, 1-Stunde-Zeitslots) mit *Mixed-Integer Programming* / ILP (exakt) via CPLEX — dabei werden die Zuweisungen als mathematisches Optimierungsproblem formuliert und mit einem kommerziellen *Solver* gelöst. Ergebnis: optimale Lösung in 78 bis 285 Sekunden. Van den Broek et al. [39] machten dasselbe an der TU Eindhoven (350 Studierende) und verwendeten *Network Flow* und ILP. „Fast alle“ Studierenden erhielten ihre Top-Präferenzen (keine genaue Zahl genannt).

University Course Timetabling (UCTTP): Alvarez-Valdes et al. [40] setzen *Tabu Search* (Metaheuristik) ein — eine lokale Suche, die bereits besuchte Lösungen auf einer Tabu-Liste speichert, um Schleifen zu vermeiden. An der Uni Valencia (4.300 Studierende) wurde der langwierige, manuelle Prozess damit automatisiert (keine Angabe zur genauen Zeitersparnis). El-mohamed et al. [41] vergleichen mehrere *Simulated-Annealing*-Varianten an der Syracuse University (13.653 Studierende, bis 3.839 Kurse, 509 Räume, 1.200 Lehrende) und zeigen: Erst die Kombination mit einem regelbasierten Vorverarbeitungsschritt liefert fehlerfreie Pläne. Wang [42] wendet einen Genetischen Algorithmus (Metaheuristik) an — inspiriert von Evolution, werden Lösungen durch Kreuzung und Mutation verbessert. Am Far East College (26 Lehrende, 90 Kurse, 10 Klassen) entstehen nach 4.000 Generationen fehlerfreie Pläne. Zhang [43] verstärkt diesen Ansatz durch einen koevolutionären Multi-Populations-GA, bei dem mehrere Gruppen von Lösungen parallel evolvieren und die besten Ergebnisse austauschen — das verhindert vorzeitiges Feststecken. Shiau [44] adaptiert *Particle Swarm Optimization* (Metaheuristik) — Lösungen bewegen sich wie ein Schwarm auf der Suche nach dem Optimum — für Stundenpläne und schlägt klassische Genetische Algorithmen in Qualität und Geschwindigkeit. Wasfy & Aloul [45] formulieren das Raumzuweisungsproblem an der American University of Sharjah sowohl als ILP als auch als SAT-Problem (exakt). Überraschend: *SAT-Solver* scheitern hier, während CPLEX alle Instanzen in unter einer Sekunde löst. Yoshikawa et al. [46] kombinierten *Constraint Programming* mit *Hill-Climbing* (hybrid) für japanische Schulen — dadurch sank der Gesamtaufwand für einen Plan

von 150 Personentagen (manuell) auf lediglich 3 Personentage.

Überblickswerk: Chen et al. [1] liefern eine umfassende Bestandsaufnahme der im letzten Jahrzehnt eingesetzten Lösungsmethoden für das UCTTP. Die Autoren klassifizieren die Ansätze in sechs Hauptgruppen: *Operational Research*, einzel- und populationsbasierte Metaheuristiken, Hyperheuristiken, Multikriterien-Ansätze sowie hybride Methoden. Ihr zentraler Befund deckt sich mit dem Bild, das sich aus den Einzelarbeiten ergibt: Metaheuristiken — allen voran *Simulated Annealing*, wie es etwa Zanazzo et al. [37] einsetzen — und hybride Verfahren dominieren die Literatur, weil sie der *NP hard*-Charakteristik des Problems am wirksamsten begegnen. Gleichzeitig zeigt die Arbeit eine Theorie-Praxis-Lücke auf: Die beschriebenen Lösungen scheitern im Realbetrieb häufig daran, dass sie die einzigartigen und oft widersprüchlichen Anforderungen einzelner Institutionen nicht flexibel genug abbilden können.

Paper-Titel	Problem-Dimension	Lösungsverfahren	Datenbasis	Wichtigste Aussagen
Optimization Algorithms for Student Scheduling (Feldman & Golumbic [12])	SSS	CSP, Tree Search, Hill-Climbing	Bar-Ilan University, Israel (synthetische Kleinstinstanzen: 30 Kurse)	Ermöglicht Studierenden interaktive, konfliktfreie Erstellung persönlicher Pläne
An exact branch-and-price approach for the medical student scheduling problem (Akbarzadeh & Maenhout [36])	SSP (Zuweisung von Medizin-studierenden)	Branch-and-Price, Dynamische Programmierung, Greedy-Heuristik, Ungarische Methode	Synthetische Datensätze (Gent, Belgien; bis 80 Studierende, 24 Disziplinen)	Bietet exakte und effiziente Lösungen unter Berücksichtigung von Präferenzen und Fairness
Solving the medical student scheduling problem using simulated annealing (Zanazzo et al. [37])	SSP	Simulated Annealing, MIP	Synthetische Benchmarks (bis 320 Studierende, bis 24 Disziplinen)	SA-basierte Suche findet optimale Lösungen in drastisch reduzierter Laufzeit (2,5 bis 48,2 Sekunden bei SA vs. 8.054 Sekunden bei MIP)
Preference-based assignment of university students to multiple teaching groups (Heitmann & Brüggemann [38])	SSP	MIP, ILP (CPLEX)	Uni Hamburg (3.735 Studierende, 300 Gruppen, 48 Kurse, 1-Stunde-Zeitslots)	Optimale Zuweisungen in 78 bis 285 Sekunden

Fortsetzung auf nächster Seite...

Tabelle 2 – Fortsetzung von vorheriger Seite

Paper-Titel	Problem-Dimension	Lösungsverfahren	Datenbasis	Wichtigste Aussagen
Timetabling problems at the TU Eindhoven (van den Broek et al. [39])	SSP	Network Flow, ILP	TU Eindhoven (350 Studierende, 60 Kurse)	Zerlegung in vier sequenzielle ILP-Teilprobleme löst das NP-schwere Problem optimal
Design and implementation of a course scheduling system using Tabu Search (Alvarez-Valdes et al. [40])	UCTTP	Tabu Search, lokale Suchheuristiken	Universität Valencia (4.300 Studierende, 84 Kurse, 93 Klassen, 24 Räume)	Das System HORARIS ersetzte den manuellen Planungsprozess durch einen „schnellen“ (keine Zeitangabe) Tabu-Search-Algorithmus, der konfliktfreie Lösungen produzierte
A Comparison of Annealing Techniques for Academic Course Scheduling (Elmohamed et al. [41])	UCTTP	Simulated Annealing (SA), Mean-Field Annealing, Expertensystem	Syracuse University (13.653 Studierende, bis 3.839 Kurse, 509 Räume, 1.200 Lehrende)	SA mit adaptiver Kühlung liefert als einzige Methode valide Pläne für Großinstanzen
Using genetic algorithm methods to solve course scheduling problems (Wang [42])	UCTTP	Genetische Algorithmen (GA)	Far East College (26 Lehrende, 90 Kurse, 10 Klassen)	Reduziert den Zeitaufwand und stößt bei Lehrenden auf höhere Akzeptanz, da Präferenzen besser abgebildet sind
An optimized solution to the course scheduling problem under an improved genetic algorithm (Zhang [43])	UCTTP	Verbesserter GA	Simulierte Daten (20 Klassen, 25 Räume, 27 Lehrende, 50 Kurse)	Multi-Populations-Koevolution verbessert Lösungsqualität (von einem Fitness-Wert von 44 bei traditionellem GA auf 48 bei verbessertem GA) bei höherem Rechenaufwand (235 bei traditionellem GA vs. 255 Sekunden bei verbessertem GA)

Fortsetzung auf nächster Seite...

Tabelle 2 – Fortsetzung von vorheriger Seite

Paper-Titel	Problem-Dimension	Lösungsverfahren	Datenbasis	Wichtigste Aussagen
A hybrid particle swarm optimization for a university course scheduling problem (Shiau [44])	UCTTP	Hybrid Particle Swarm Optimization (HPSO), Lokale Suche	Kun-Shan & Fooyin Uni (Taiwan), reale Daten, 3 Problemkategorien: Klein (17 Lehrende, 8 Klassen, 40 Zeitrahmen), Mittel (32 Lehrende, 16 Klassen, 40 Zeitrahmen) und Groß (49 Lehrende, 28 Klassen, 40 Zeitrahmen)	Übertrifft GA in allen Problemgrößen: Klein (3,85 Sekunden HPSO vs. 58,95 Sekunden GA), Mittel (9,13 vs. 108,27 Sek.), Groß (25,08 vs. 213,26 Sek.)
Solving the University Class Scheduling Problem (Wasfy & Aloul [45])	UCTTP	0-1 ILP, SAT	Uni Sharjah (UAE), Echt-Daten (Kurse pro Instanz: 3 – 12) und zufällig generierte Testfälle (20 – 100 Kurse, 10 – 70 Studierende)	ILP-Solver (CPLEX) schlagen SAT-Ansätze und finden Optima meist in unter einer Sekunde (0,01 – 0,3 Sek. bei CPLEX vs. >1000 Sek. bei SAT)
A Constraint-Based High School Scheduling System (Yoshikawa et al. [46])	UCTTP (High School)	Constraint Programming, Hill Climbing	Japanische High Schools, verschiedene Schulen und Probleme (30 – 34 Klassen, 33 – 34 Zeitfenster, 668 – 930 Lehreinheiten)	Senkt Arbeitsaufwand von 150 Personentagen auf 3 Personentage
A Survey of University Course Timetabling Problem (Chen et al. [1])	UCTTP (Review)	Diverse	Literaturrecherche	Metaheuristiken begegnen <i>NP hard</i> -Charakteristik von UCTTP am Besten. Anwendungen, die in Benchmarks gut funktionieren, scheitern in der Praxis oft an individuellen Problemen und Anforderungen der Institution

Tabelle 2: Übersicht der Forschungsliteratur zu University Timetabling Problemen

8.3 Schlussworte

Diese Bachelorarbeit hatte zum Ziel, die Algorithmen von Feldman und Golumbic [12] unter heutigen Bedingungen zu evaluieren und ihre Anwendbarkeit auf einen realen Datensatz der Wirtschaftsuniversität Wien zu überprüfen. Rückblickend lässt sich festhalten, dass dieses Ziel erreicht wurde — und dass die Arbeit dabei sowohl erwartete als auch überraschende Erkenntnisse

geliefert hat.



Die Kernaussage von Feldman und Golumbic, dass *Offering-Order* hinsichtlich der Laufzeit den *Hill-Climbing*-Ansätzen überlegen ist, konnte bestätigt werden. Ebenso zeigte sich, dass *Hill-Climbing* in der Lösungsqualität robust abschneidet.



Die vielleicht überraschendste Erkenntnis dieser Arbeit ist jedoch die Effizienz moderner ILP-*Solver*. Dass ein exaktes Verfahren die heuristischen Algorithmen in der Laufzeit in fast allen Szenarien übertrifft, war im Vorfeld nicht erwartet worden. Für die Praxis bedeutet das, dass der vermeintliche Trade-off zwischen Lösungsqualität und Geschwindigkeit — der die Motivation für Heuristiken historisch begründet hat — für Probleminstanzen der hier betrachteten Größenordnung nicht mehr zwingend gilt.

Dennoch sollte man die Limitierungen dieser Arbeit beachten. Die Evaluation beschränkt sich auf einen einzigen Datensatz eines einzelnen Semesters, und die implementierten Algorithmusvarianten decken nicht das gesamte Spektrum der Originalarbeit ab. Die Szenarien wurden nur einzeln für sich getestet. Wie sich die Ergebnisse verhalten, wenn man Szenarien kombiniert, wurde nicht geprüft. Ob die Ergebnisse auf andere Bedingungsarten in Studienprogrammen oder größere Probleminstanzen übertragbar sind, bleibt eine offene Frage.



9 Anhang



9.1 Szenario 1: Keine Kurse an Montagen









9.2 Szenario 2: Keine Kurse an Freitagen









9.3 Szenario 3: Jeder Tag der Woche bis 9:45 frei









9.4 Szenario 4: Keine Kurse an Donnerstagen und Freitagen









9.5 Szenario 5: Erhöhte Priorität (+90) für Nachmittags, negative Priorität (-90) für Abend









9.6 Szenario 6: Erhöhte Priorität (+70) für Vormittag, neutrale Priorität (0) für Nachmittag, negative Priorität (-80) für Abend









9.7 Szenario 7: Studierende müssen von 12:00 bis 13:00 Zeit für ein Mittagessen haben









9.8 Szenario 8: Studierende müssen mehr als einen Kurs pro Tag besuchen









9.9 Szenario 9: Studierende dürfen nicht mehr als drei Kurse pro Tag besuchen









9.10 Szenario 10: Alle Kurse können frei von Constraints gewählt werden









9.11 Szenario 11: 25%- 75% aller Kurse können nicht belegt werden.









9.12 Szenario 12: 1 - 7 Kurse sind vorgegeben









9.13 Szenario 13: Keine Kurse zwischen 6:00 morgens und 13:00





9.14 Szenario 14: Keine Kurse Montags, Dienstags und Mittwochs





Literatur

- [1] M. C. Chen, S. N. Sze, S. L. Goh, N. R. Sabar und G. Kendall, „A Survey of University Course Timetabling Problem: Perspectives, Trends and Opportunities,“ *IEEE Access*, Jg. 9, S. 106 515–106 529, 2021. DOI: 10.1109/ACCESS.2021.3100613
- [2] A. Muklason, A. J. Parkes, E. Özcan, B. McCollum und P. McMullan, „Fairness in examination timetabling: Student preferences and extended formulations,“ *Applied Soft Computing*, Jg. 55, S. 302–318, Jan. 2017. DOI: 10.1016/j.asoc.2017.01.026
- [3] H. T. -. T. U. of Applied Sciences. „Evaluation zu den Freiräumen im Stundenplan,“ besucht am 10. Apr. 2026. Adresse: <https://www.hochschule-trier.de/hauptcampus/bauen-plus-leben/gve/fachrichtung/aktuelles/news/detailansicht/evaluation-zu-den-freiraeumen-im-stundenplan>
- [4] P. Cowling, G. Kendall und N. M. Hussin, „A survey and case study of practical examination timetabling problems,“ in *Proc. 4th International Conference on the Practice and Theory of Automated Timetabling (PATAT02)*, 2002, S. 258–261.
- [5] Ö.-W. Studienplaner, besucht am 10. Apr. 2026. Adresse: <https://studienplaner.oeh-wu.at/>
- [6] UniTime, besucht am 10. Apr. 2026. Adresse: <https://www.unitime.org/>
- [7] T. Müller und K. Murray, „Comprehensive approach to student sectioning,“ *Annals of Operations Research*, Jg. 181, Nr. 1, S. 249–269, März 2010. DOI: 10.1007/s10479-010-0735-9
- [8] I. C. Schedulung, besucht am 10. Apr. 2026. Adresse: <https://infosilem.com/en>
- [9] C. C. Schedulung, besucht am 10. Apr. 2026. Adresse: <https://www.coursedog.com/>
- [10] MyStudyLife, besucht am 10. Apr. 2026. Adresse: <https://mystudylife.com/>
- [11] uAchieve Schedule Builder, besucht am 10. Apr. 2026. Adresse: <https://collegesource.com/degree-planning-tools/uachieve-schedule-builder>
- [12] R. Feldman und M. C. Golumbic, „Optimization Algorithms for Student Scheduling via Constraint Satisfiability,“ *The Computer Journal*, Jg. 33, Nr. 4, S. 356–364, Apr. 1990. DOI: 10.1093/comjnl/33.4.356

- [13] L. E. Burman, W. R. Reed und J. Alm, „A Call for Replication Studies“, *Public Finance Review*, Jg. 38, Nr. 6, S. 787–793, Okt. 2010. DOI: 10.1177/1091142110385210
- [14] G. K. Sandve, A. Nekrutenko, J. Taylor und E. Hovig, „Ten Simple Rules for Reproducible Computational Research“, *PLoS Computational Biology*, Jg. 9, Nr. 10, e1003285, Okt. 2013. DOI: 10.1371/journal.pcbi.1003285
- [15] P. Scheer. „Bachelorarbeit – Quellcode.“ Relevante Dateien:
models/hill_climbing_v1.py – Hill-Climbing v1 Algorithmus
models/hill_climbing_v3.py – Hill-Climbing v3 Algorithmus
models/offering_order.py – Offering-Order Algorithmus
models/ilp.py – ILP-Modell (CPU)
models/ilp_gpu.py – ILP-Modell (GPU)
bachelorarbeit/dataset.py – Skript zur Verarbeitung des VVZ-Datensatzes
data/raw/vvz_model.pkl – Rohdaten des VVZ-Modells
models/results_to_csv.py – Skript zur Konvertierung der Benchmark-Ergebnisse in CSV
results/raw/results.zip – Rohergebnisse aller Benchmarks, besucht am 10. Apr. 2026. Adresse: <https://github.com/philippscheer/bachelorarbeit>
- [16] Wirtschaftsuniversität Wien. „Studienplan für das Bachelorstudium Wirtschafts- und Sozialwissenschaften“, besucht am 10. Apr. 2026. Adresse: https://www.wu.ac.at/fileadmin/wu/h/students/Studienpl%C3%A4ne_Import/BaWISO_2019_30.06.2022/Bachelor_WiSo_30.06.22.pdf
- [17] D. Beyer, S. Löwe und P. Wendler, „Reliable Benchmarking: Requirements and Solutions“, *International Journal on Software Tools for Technology Transfer*, Jg. 21, Nr. 1, S. 1–29, 2019. DOI: 10.1007/s10009-017-0469-y
- [18] S. Ceschia, L. Di Gaspero und A. Schaerf, „Educational timetabling: Problems, benchmarks, and state-of-the-art results“, *European Journal of Operational Research*, Jg. 308, Nr. 1, S. 1–18, Juli 2022. DOI: 10.1016/j.ejor.2022.07.011
- [19] M. W. Carter, G. Laporte und S. Y. Lee, „Examination Timetabling: Algorithmic Strategies and Applications“, *Journal of the Operational Research Society*, Jg. 47, Nr. 3, S. 373–383, März 1996. DOI: 10.1057/jors.1996.37

- [20] H. Rudová und K. Murray, *University Course Timetabling with Soft Constraints*. Jan. 2003, S. 310–328. DOI: 10.1007/978-3-540-45157-0\{_\}21
- [21] A. Schaerf, „A survey of Automated Timetabling,“ *Artificial Intelligence Review*, Jg. 13, Nr. 2, S. 87–127, Apr. 1999. DOI: 10.1023/a:1006576209967
- [22] M. Dostert, A. Politz und H. Schmitz, „A complexity analysis and an algorithmic approach to student sectioning in existing timetables,“ *Journal of Scheduling*, Jg. 19, Nr. 3, S. 285–293, Apr. 2015. DOI: 10.1007/s10951-015-0424-2
- [23] W. Z. A. W. Muhamad, F. A. Adnan, Z. R. Yahya, A. K. Junoh und M. H. Zakaria, „Solving university course timetabling problems using FET software,“ *AIP conference proceedings*, Jg. 2013, S. 020 052, Jan. 2018. DOI: 10.1063/1.5054251
- [24] J. Nielsen. „Response times: The 3 important limits,“ besucht am 10. Apr. 2026. Adresse: <https://www.nngroup.com/articles/response-times-3-important-limits/>
- [25] R. E. Bixby, „A brief history of linear and mixed-integer programming computation,“ in *Optimization Stories*, European Mathematical Society-EMS-Publishing House GmbH, 2012, S. 107–121.
- [26] A. M. Newman und M. Weiss, „A survey of Linear and Mixed-Integer optimization tutorials,“ *INFORMS Transactions on Education*, Jg. 14, Nr. 1, S. 26–38, Sep. 2013. DOI: 10.1287/ited.2013.0115
- [27] F. Clautiaux und I. Ljubić, „Last fifty years of integer linear programming: A focus on recent practical advances,“ *European Journal of Operational Research*, Jg. 324, Nr. 3, S. 707–731, Nov. 2024. DOI: 10.1016/j.ejor.2024.11.018
- [28] D. J. Simons, „The value of direct replication,“ *Perspectives on Psychological Science*, Jg. 9, Nr. 1, S. 76–80, Jan. 2014. DOI: 10.1177/1745691613514755
- [29] M. Engineering, E. National Academies of Sciences, Medicine u. a., „Reproducibility and replicability in science,“ Mai 2019. DOI: 10.17226/25303
- [30] F. Middleton. „Reliability vs Validity in Research | Differences, Types & Examples,“ besucht am 10. Apr. 2026. Adresse: <https://www.scribbr.co.uk/research-methods/reliability-or-validity/>

- [31] I.-C. A. Chiang, R. S. Jhangiani und P. C. Price, „Reliability and validity of measurement,“ *Research methods in psychology*, Okt. 2015.
- [32] D. G. Bonett, „Design and Analysis of Replication Studies,“ *Organizational Research Methods*, Jg. 24, Nr. 3, S. 513–529, März 2020. DOI: 10.1177/1094428120911088
- [33] M. J. Brandt u. a., „The Replication Recipe: What makes for a convincing replication?“ *Journal of Experimental Social Psychology*, Jg. 50, S. 217–224, Okt. 2013. DOI: 10.1016/j.jesp.2013.10.005
- [34] V. der Wirtschaftsuniversität Wien, besucht am 10. Apr. 2026. Adresse: <https://vvz.wu.ac.at/>
- [35] R. des CBC PuLP Solver, besucht am 10. Apr. 2026. Adresse: <https://github.com/coin-or/Cbc>
- [36] B. Akbarzadeh und B. Maenhout, „An exact branch-and-price approach for the medical student scheduling problem,“ *Computers & Operations Research*, Jg. 129, S. 105 209, 2021. DOI: 10.1016/j.cor.2021.105209
- [37] E. Zanazzo, S. Ceschia, A. Dovier und A. Schaerf, „Solving the medical student scheduling problem using simulated annealing,“ *Journal of Scheduling*, Jg. 28, Nr. 2, S. 233–246, 2025. DOI: 10.1007/s10951-024-00806-z
- [38] H. Heitmann und W. Brüggemann, „Preference-based assignment of university students to multiple teaching groups,“ *OR spectrum*, Jg. 36, Nr. 3, S. 607–629, 2014. DOI: 10.1007/s00291-013-0332-9
- [39] J. Van den Broek, C. Hurkens und G. Woeginger, „Timetabling problems at the TU Eindhoven,“ *European Journal of Operational Research*, Jg. 196, Nr. 3, S. 877–885, 2009. DOI: 10.1016/j.ejor.2008.04.038
- [40] R. Alvarez-Valdes, E. Crespo und J. M. Tamarit, „Design and implementation of a course scheduling system using tabu search,“ *European Journal of Operational Research*, Jg. 137, Nr. 3, S. 512–523, 2002. DOI: 10.1016/S0377-2217(01)00091-1
- [41] M. S. Elmohamed, P. Coddington und G. Fox, „A comparison of annealing techniques for academic course scheduling,“ in *Proc. International Conference on the Practice and Theory of Automated Timetabling*, Springer, 1997, S. 92–112. DOI: 10.1007/BFb0055883

- [42] Y.-Z. Wang, „Using genetic algorithm methods to solve course scheduling problems,“ *Expert Systems with Applications*, Jg. 25, Nr. 1, S. 39–50, 2003. DOI: 10.1016/S0957-4174(03)00004-6
- [43] Q. Zhang, „An optimized solution to the course scheduling problem in universities under an improved genetic algorithm,“ *Journal of Intelligent Systems*, Jg. 31, Nr. 1, S. 1065–1073, 2022. DOI: 10.1515/jisys-2022-0114
- [44] D.-F. Shiau, „A hybrid particle swarm optimization for a university course scheduling problem with flexible preferences,“ *Expert Systems with Applications*, Jg. 38, Nr. 1, S. 235–248, 2011. DOI: 10.1016/j.eswa.2010.06.051
- [45] A. Wasfy und F. Aloul, „Solving the university class scheduling problem using advanced ILP techniques,“ in *Proc. IEEE GCC Conference*, 2007, S. 1–5.
- [46] M. Yoshikawa, K. Kaneko, T. Yamanouchi und M. Watanabe, „A constraint-based high school scheduling system,“ *IEEE Expert*, Jg. 11, Nr. 1, S. 63–72, 1996. DOI: 10.1109/64.482960

